# Нейросетевые языковые модели

Евгений Борисов

# Нейросетевые языковые модели

**Языковая модель**
- предсказываем следующее слово на основе предыдущих
- оценка (вероятность) совместимости цепочки слов

**Оценка цепочки слов (биграммная модель):**

$$p(w_1 \dots w_n) = \prod_{k=1}^{n} p(w_k | w_{k-1})$$

$$p(w_n | w_{n-1}) = \frac{C(w_{n-1} w_n)}{C(w_{n-1})}$$

P - вероятность совместного использования слов

C(w) – количество слов w в тексте

# Нейросетевые языковые модели

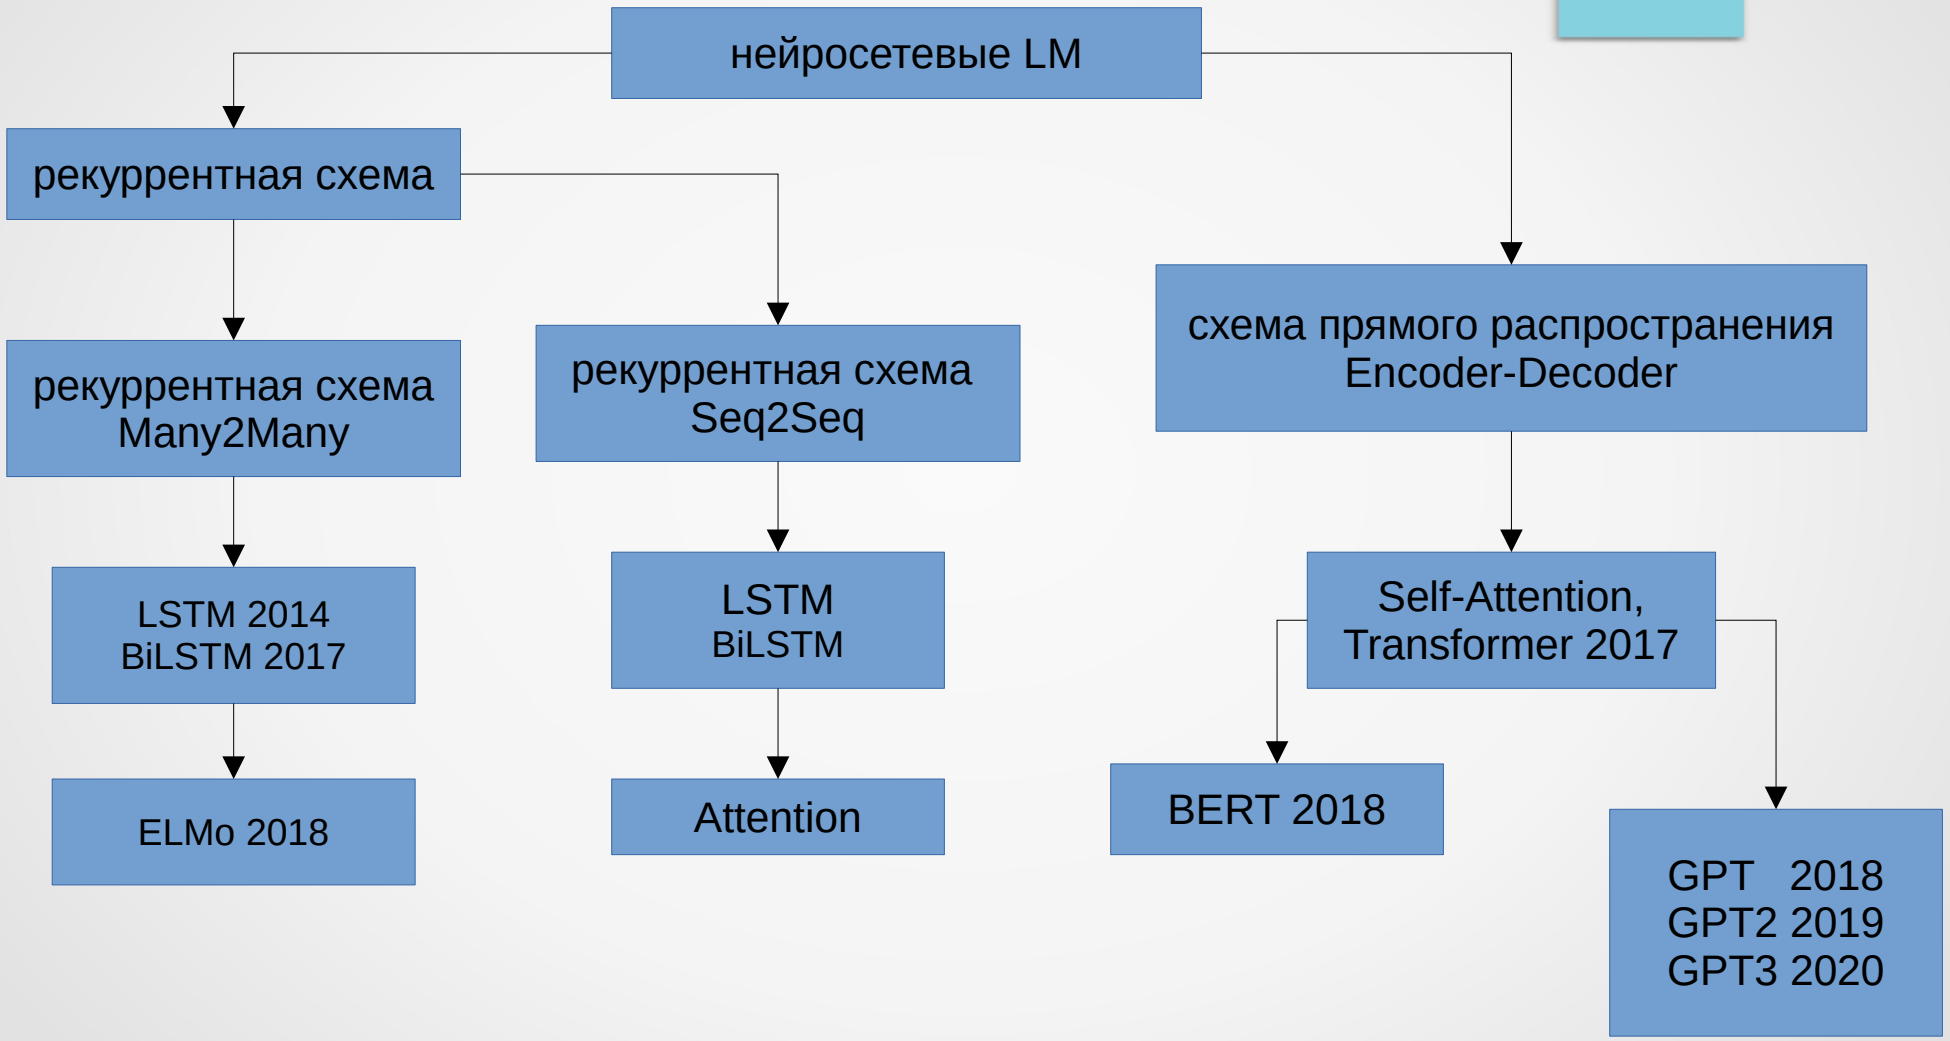

# Нейросетевые языковые модели

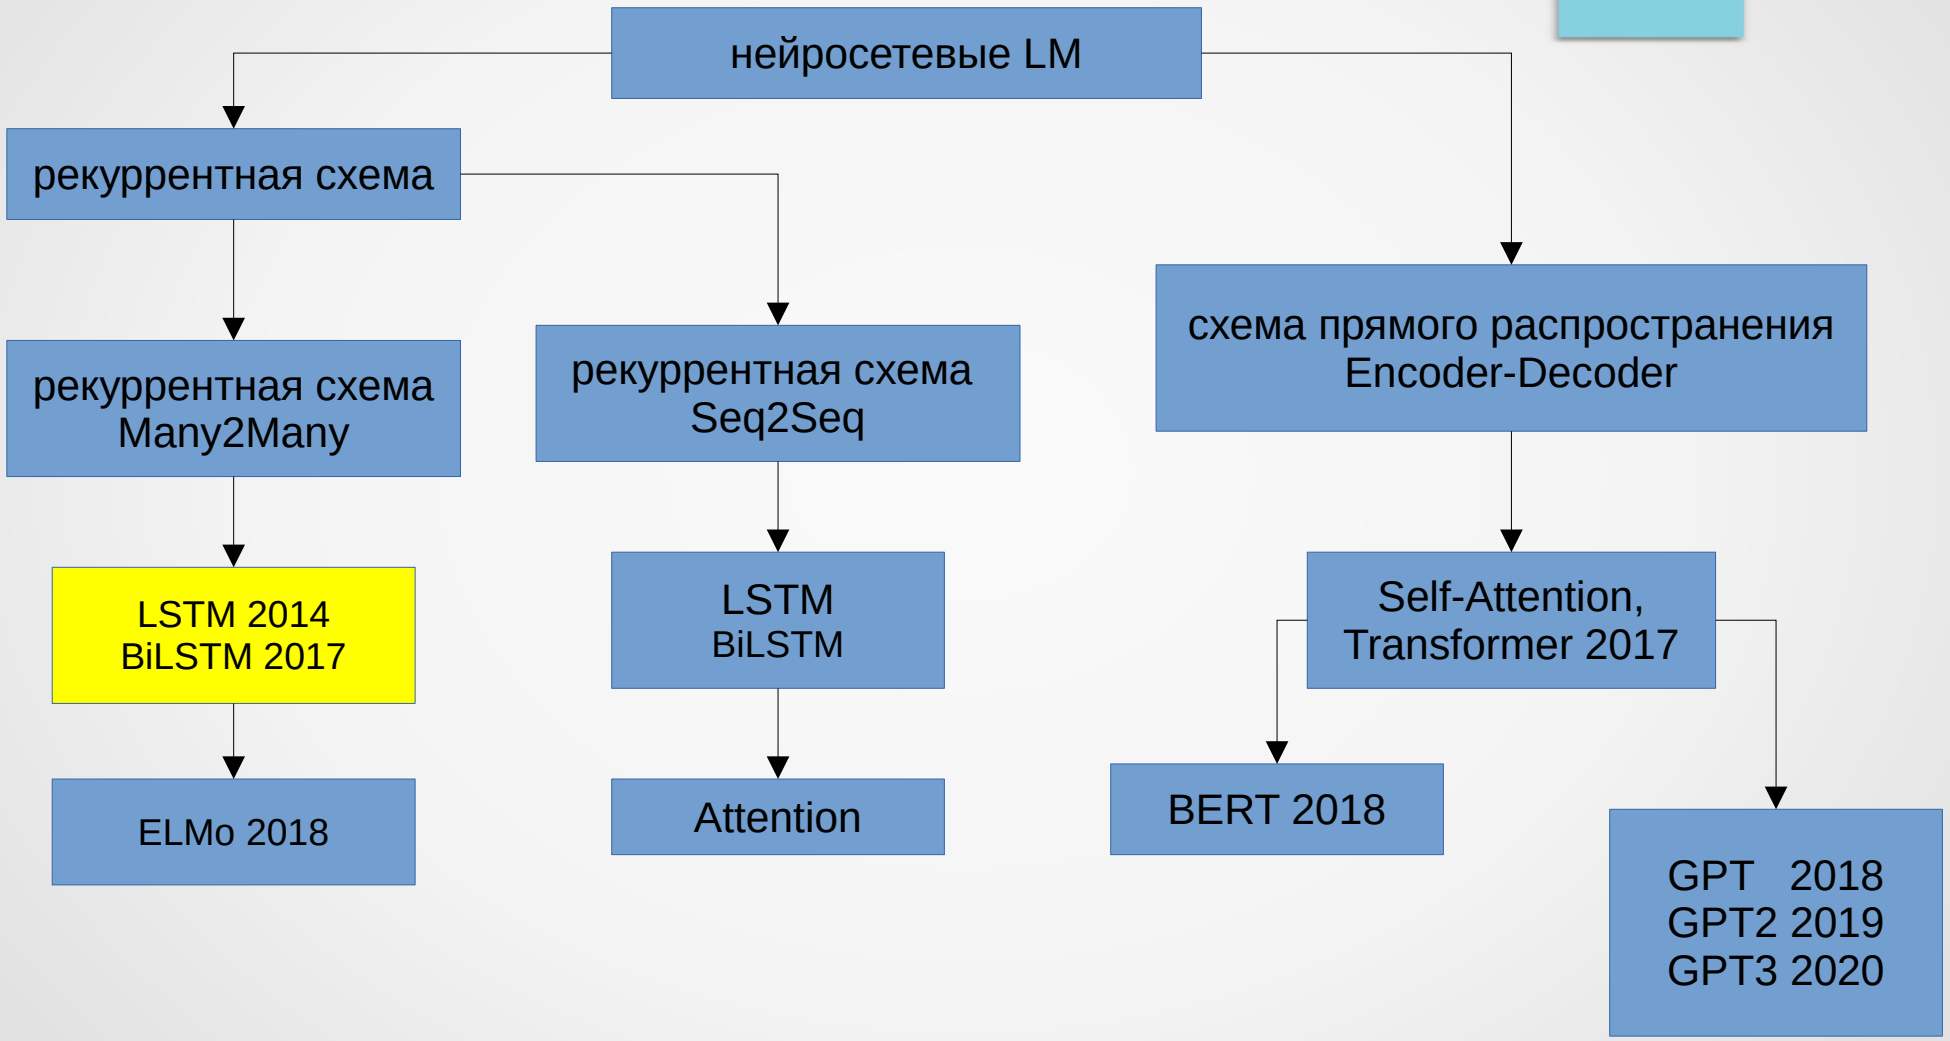

# Нейросетевые языковые модели

**Простая схема с рекуррентной сетью**

Предсказываем следующее слово по предыдущему контексту

получаем word embedding, который учитывает левый контекст

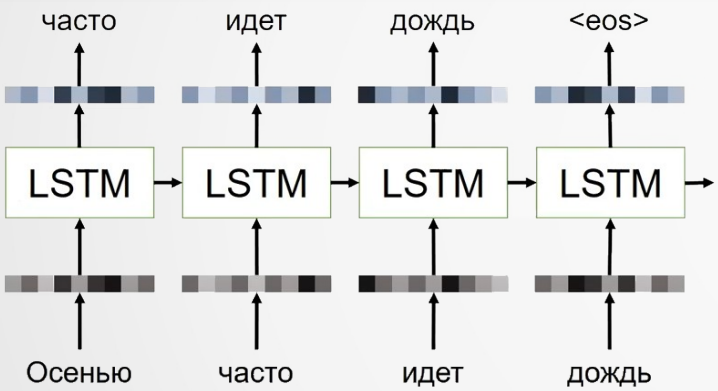


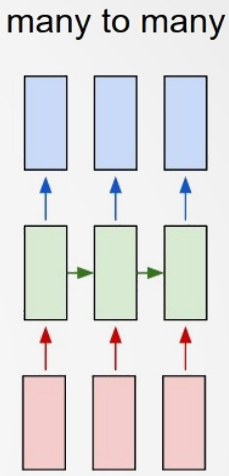


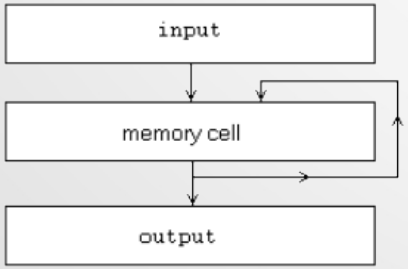


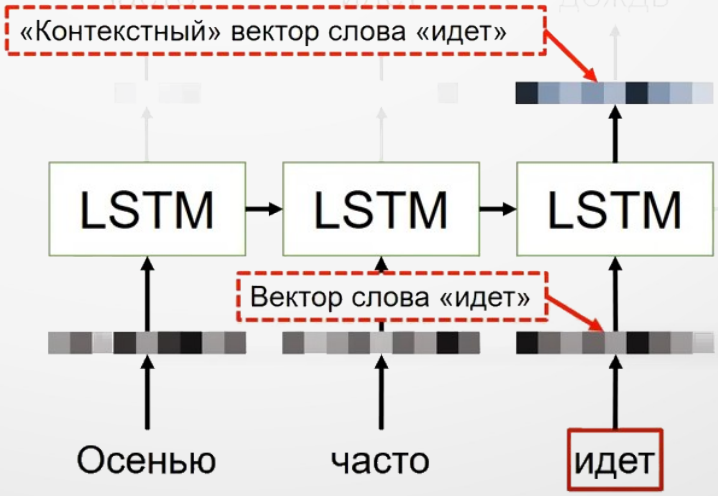


https://www.youtube.com/watch?v=_8MGdpt4I9M

# Нейросетевые языковые модели

**Двунаправленная схема**
(Peters M. E. et al. Semi-supervised sequence tagging with bidirectional language models – 2017.)

используем две сети (по два слоя) и два контекста - левый и правый

два представления (выхода) агрегируем

получаем word embedding, который учитывает левый и правый контекст

Прямая модель: $p(w_1, \dots, w_N) = \prod_{k=1}^{N} p(w_k | w_1, \dots, w_{k-1})$

Обратная модель: $p(w_1, \dots, w_N) = \prod_{k=1}^{N} p(w_k | w_{k+1}, \dots, w_N)$

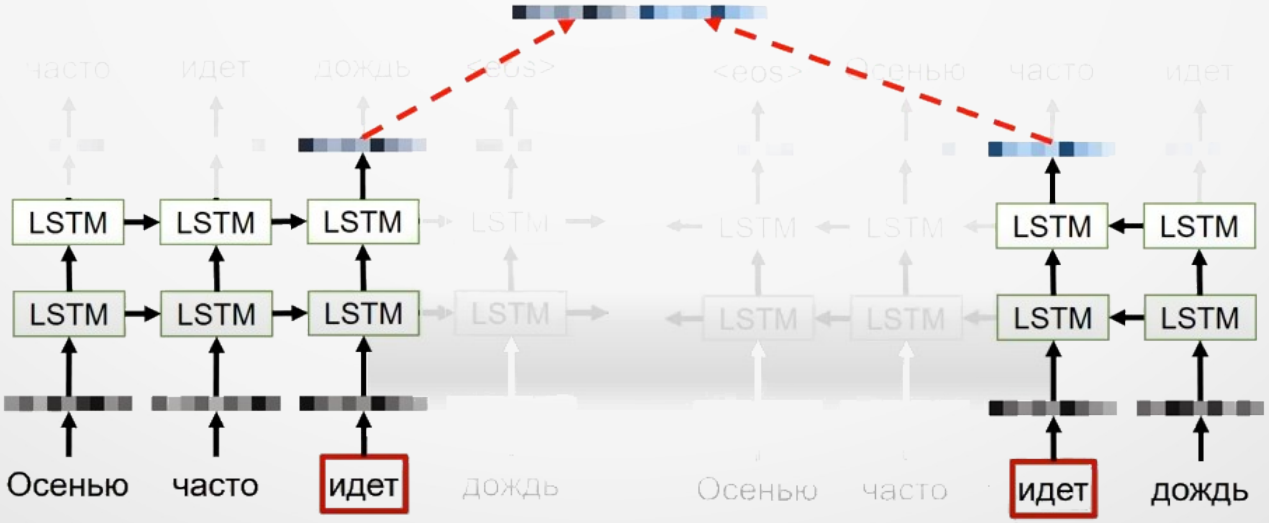


https://www.youtube.com/watch?v=_8MGdpt4I9M

# Нейросетевые языковые модели

# Нейросетевые языковые модели

## ELMo (Embeddings from Language Models)

(Peters M. E. et al. Deep contextualized word representations – 2018.)

Обучаем модель на левый и правый контекст одновременно

$$J = \sum_{k=1}^{N} [\log p(w_k | w_1, \dots, w_{k-1}; \Theta_x, \Theta_{\overrightarrow{LSTM}}, \Theta_s) + \log p(w_k | w_{k+1}, \dots, w_N; \Theta_x, \Theta_{\overleftarrow{LSTM}}, \Theta_s)]$$

получаем word embedding как агрегированный выход модели - взвешенная сумма всех промежуточных выходов на правом и левом контексте

$$ELMo_k = \gamma^{task} \sum_{j=0}^{L} s_j^{task} h_{k,j}^{LM}, \text{где } h_{k,i}^{LM} = [\overrightarrow{h}_{k,i}^{LM}; \overleftarrow{h}_{k,i}^{LM}], i = \overline{1,n}$$

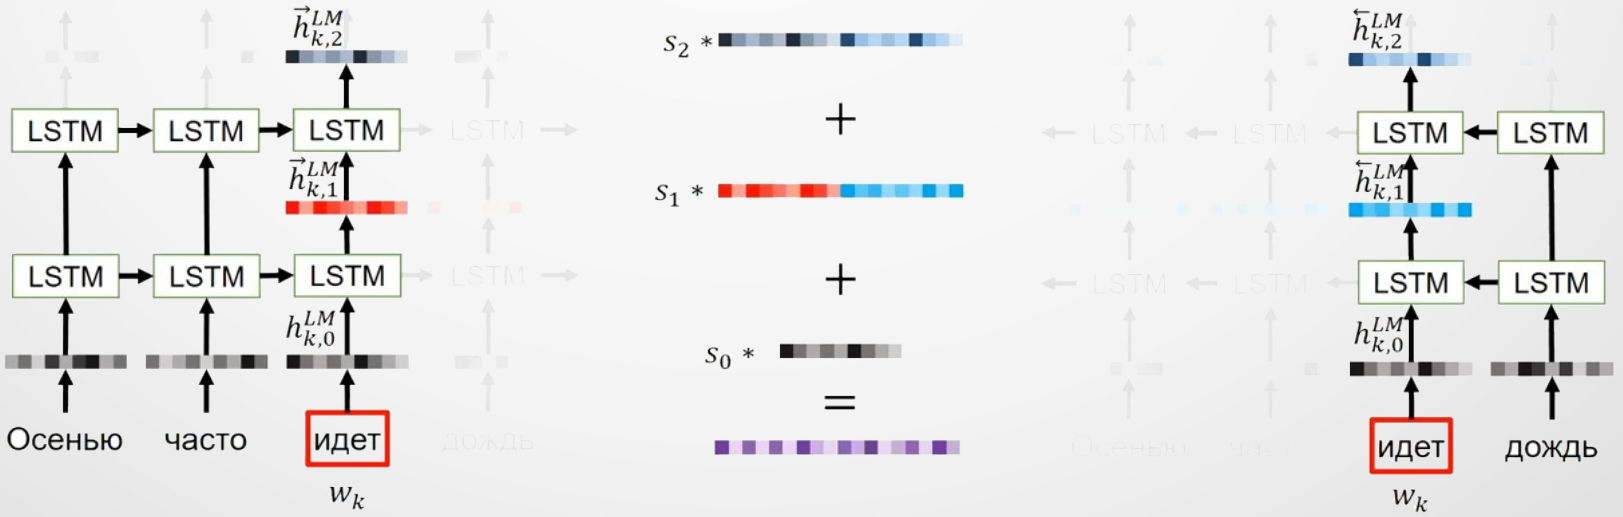


https://www.youtube.com/watch?v=_8MGdpt4I9M

# Нейросетевые языковые модели

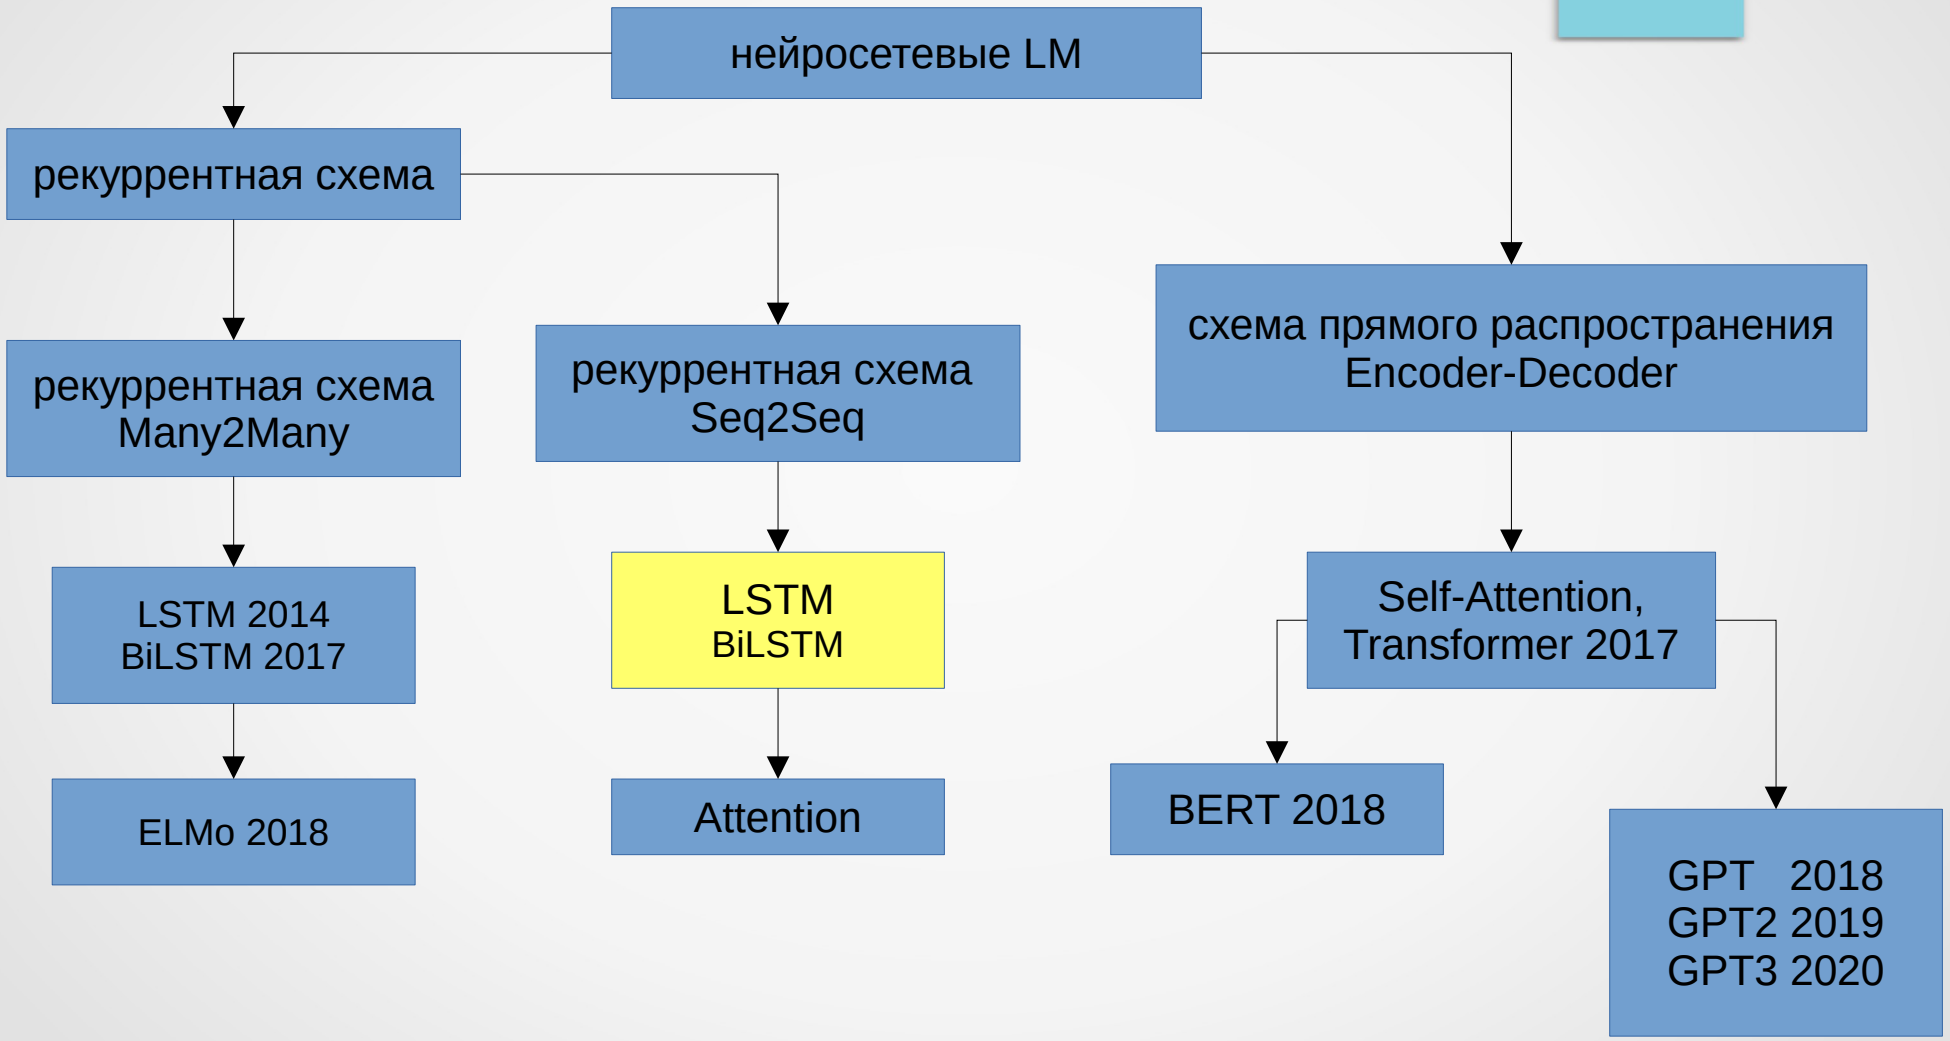

# Нейросетевые языковые модели

**Рекуррентная схема SEQ2SEQ**

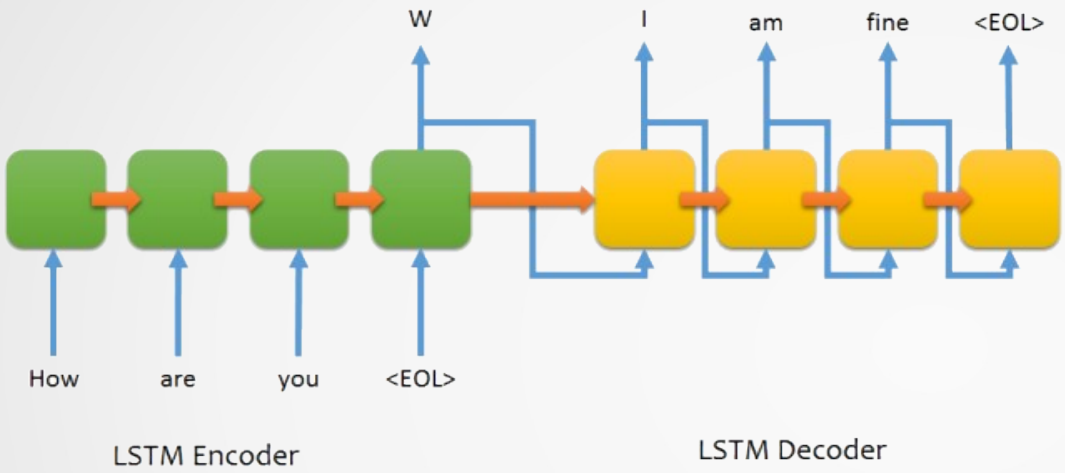


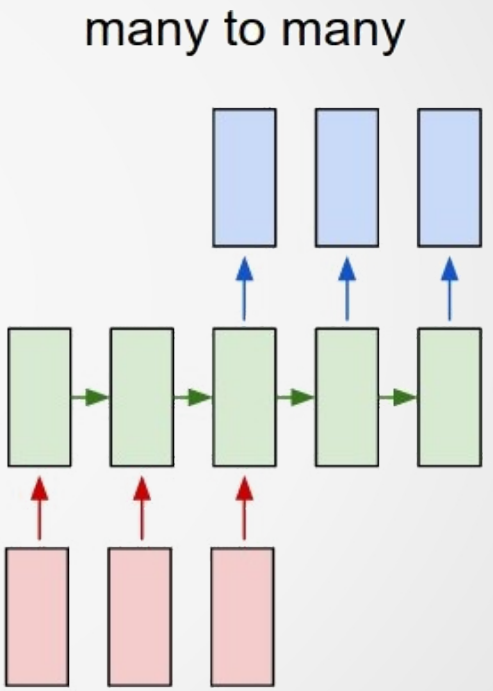


пара рекуррентных неросетей

- кодировщик,
формирует внутреннее представление

- декодировщик,
авторегрессионная модель,
разворачивает состояние энкодера

# Нейросетевые языковые модели

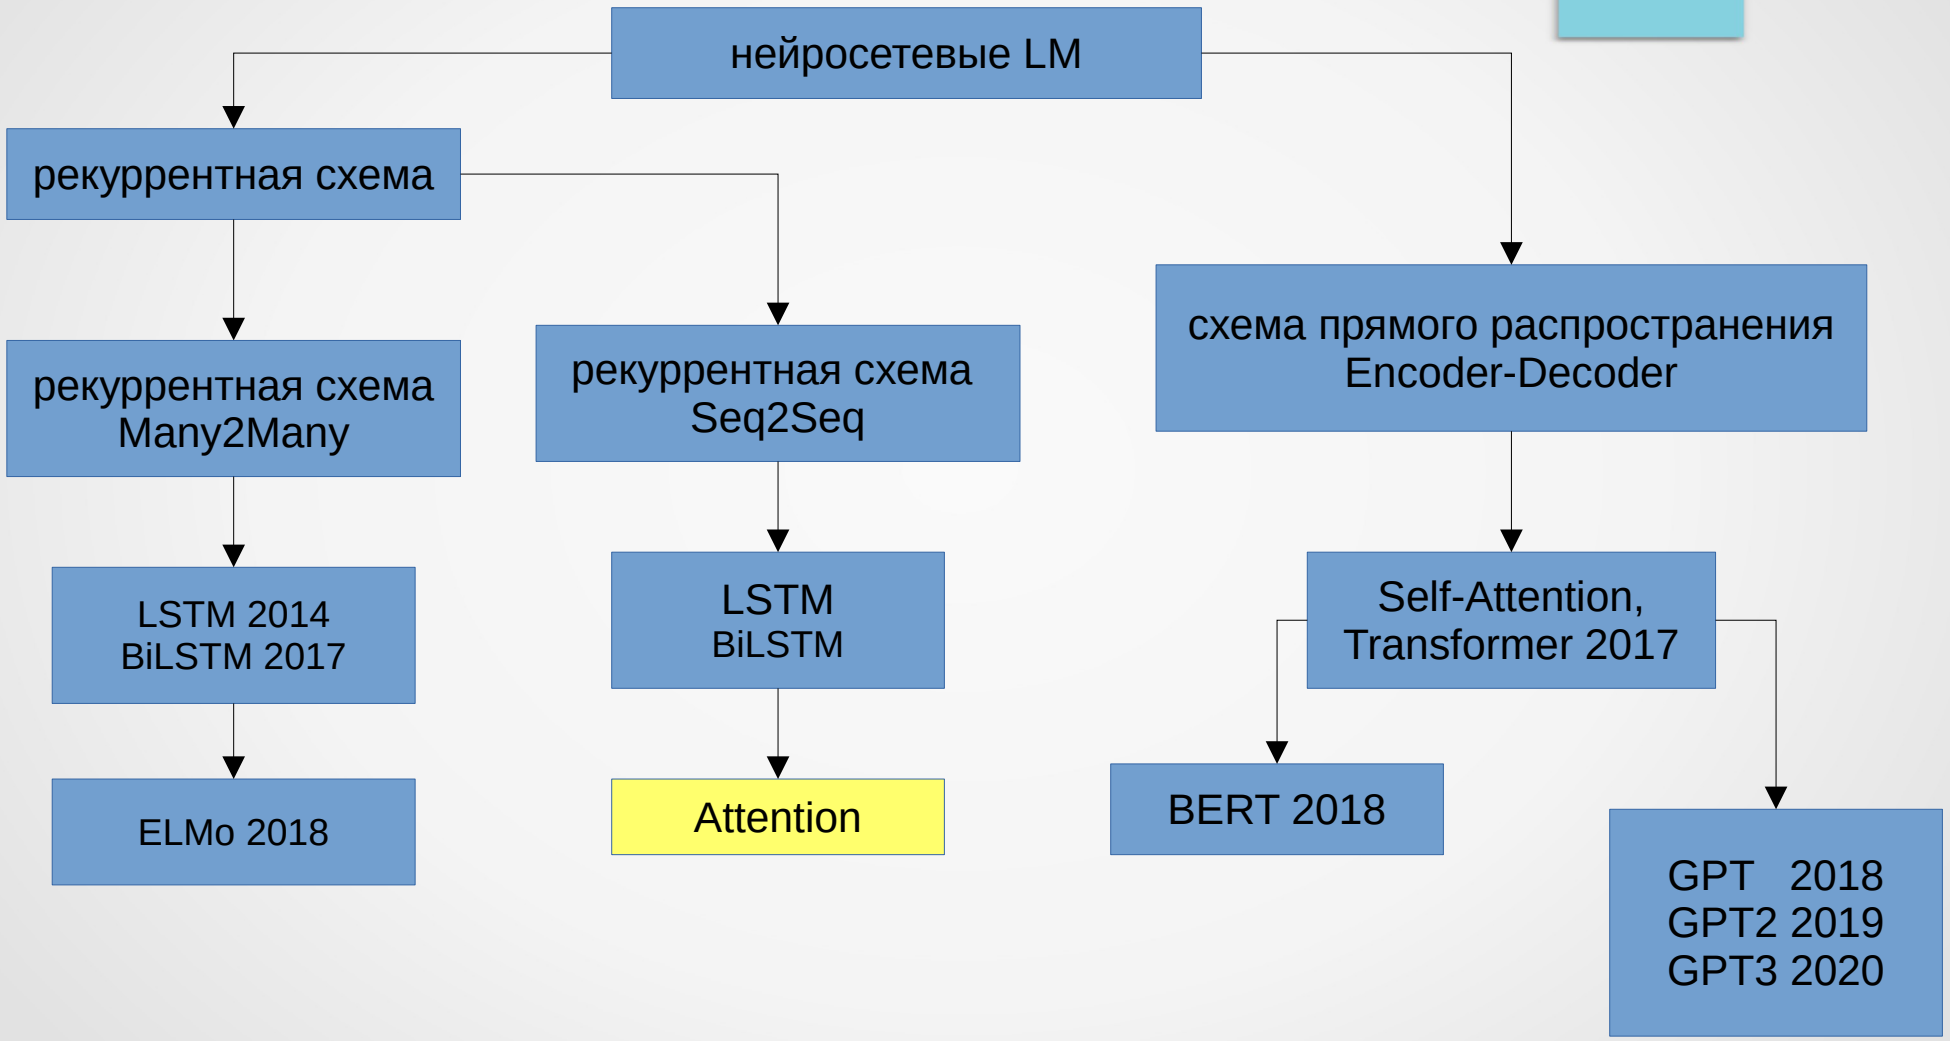

# Нейросетевые языковые модели

**Рекуррентная схема SEQ2SEQ**

проблема: модель может "забывать" начальный контекст

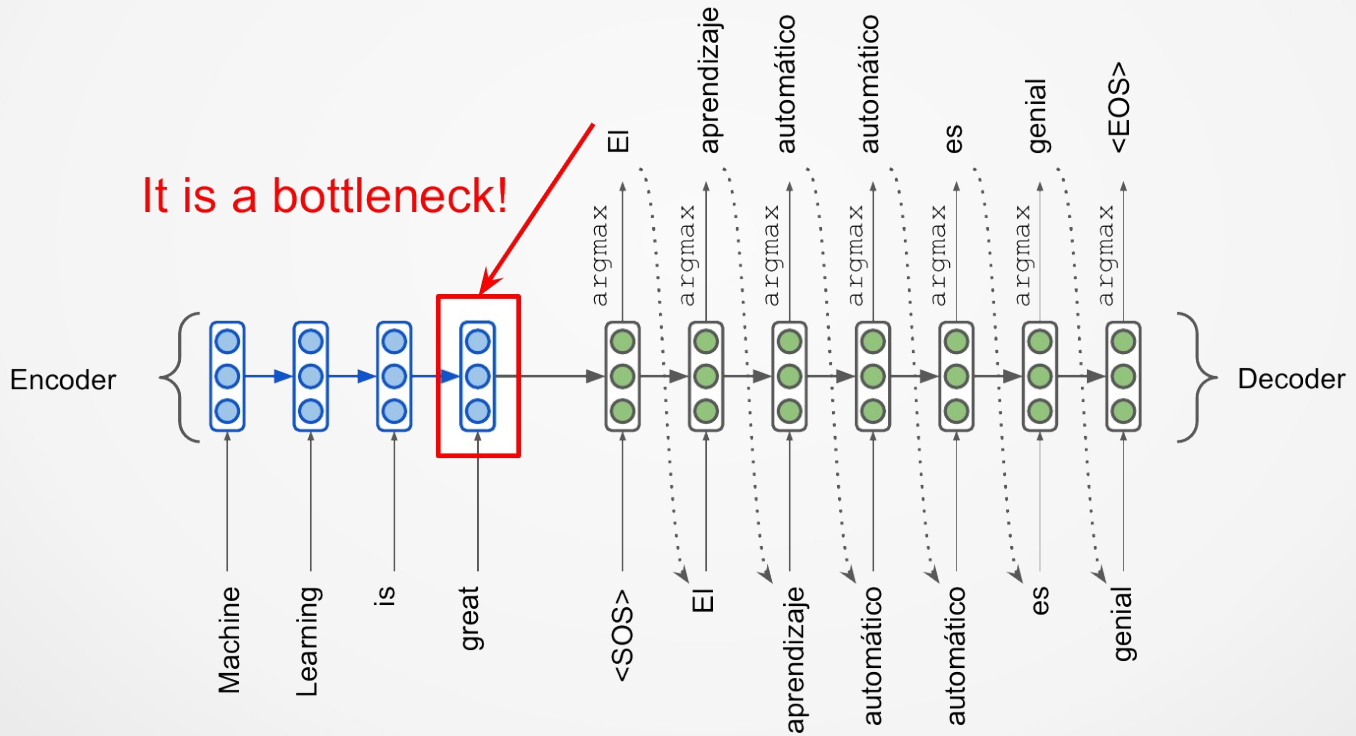


https://www.youtube.com/watch?v=6HibilFua-U

# Нейросетевые языковые модели

**Рекуррентная схема SEQ2SEQ и механизм внимания (Attention)**

- считаем коэффициенты внимания
- добавляем к состоянию декодера взвешенную сумму входов

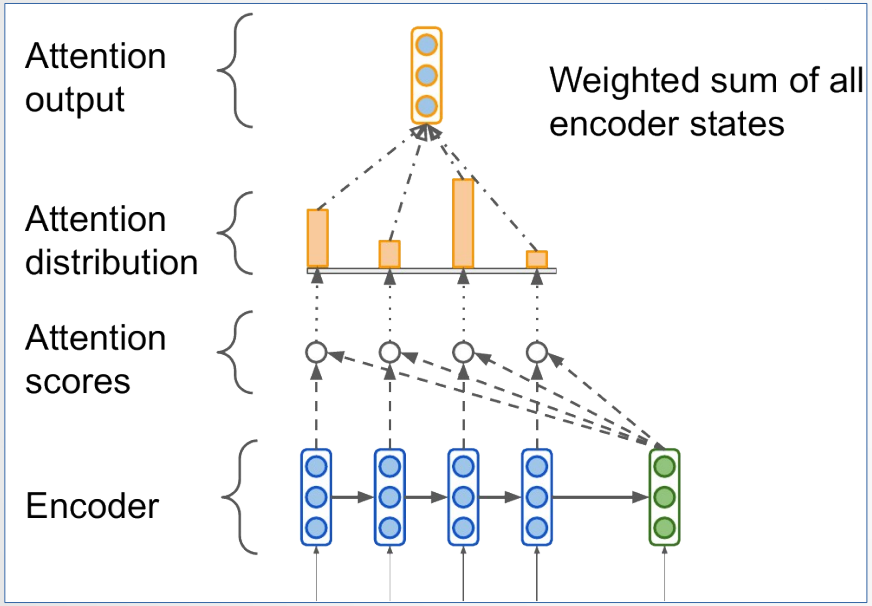


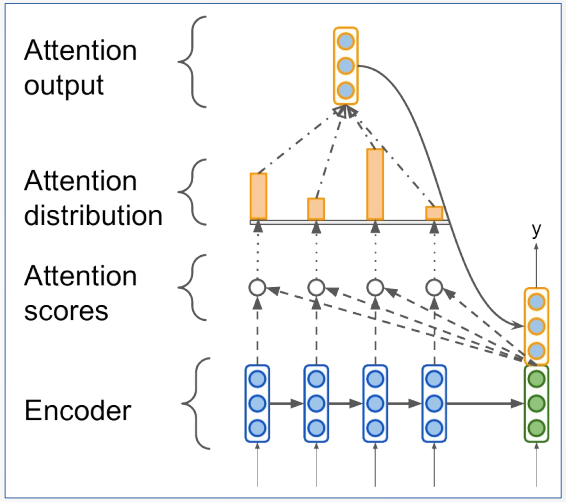


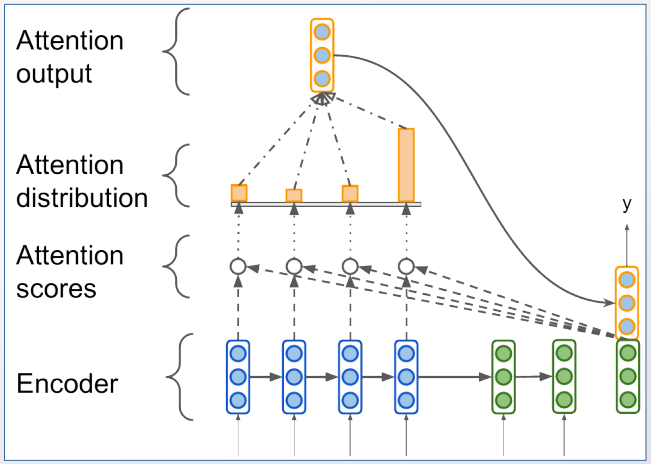


все слова подаём в модель последовательно,
схему вычислений трудно распараллелить

https://www.youtube.com/watch?v=6HibilFua-U

# Нейросетевые языковые модели

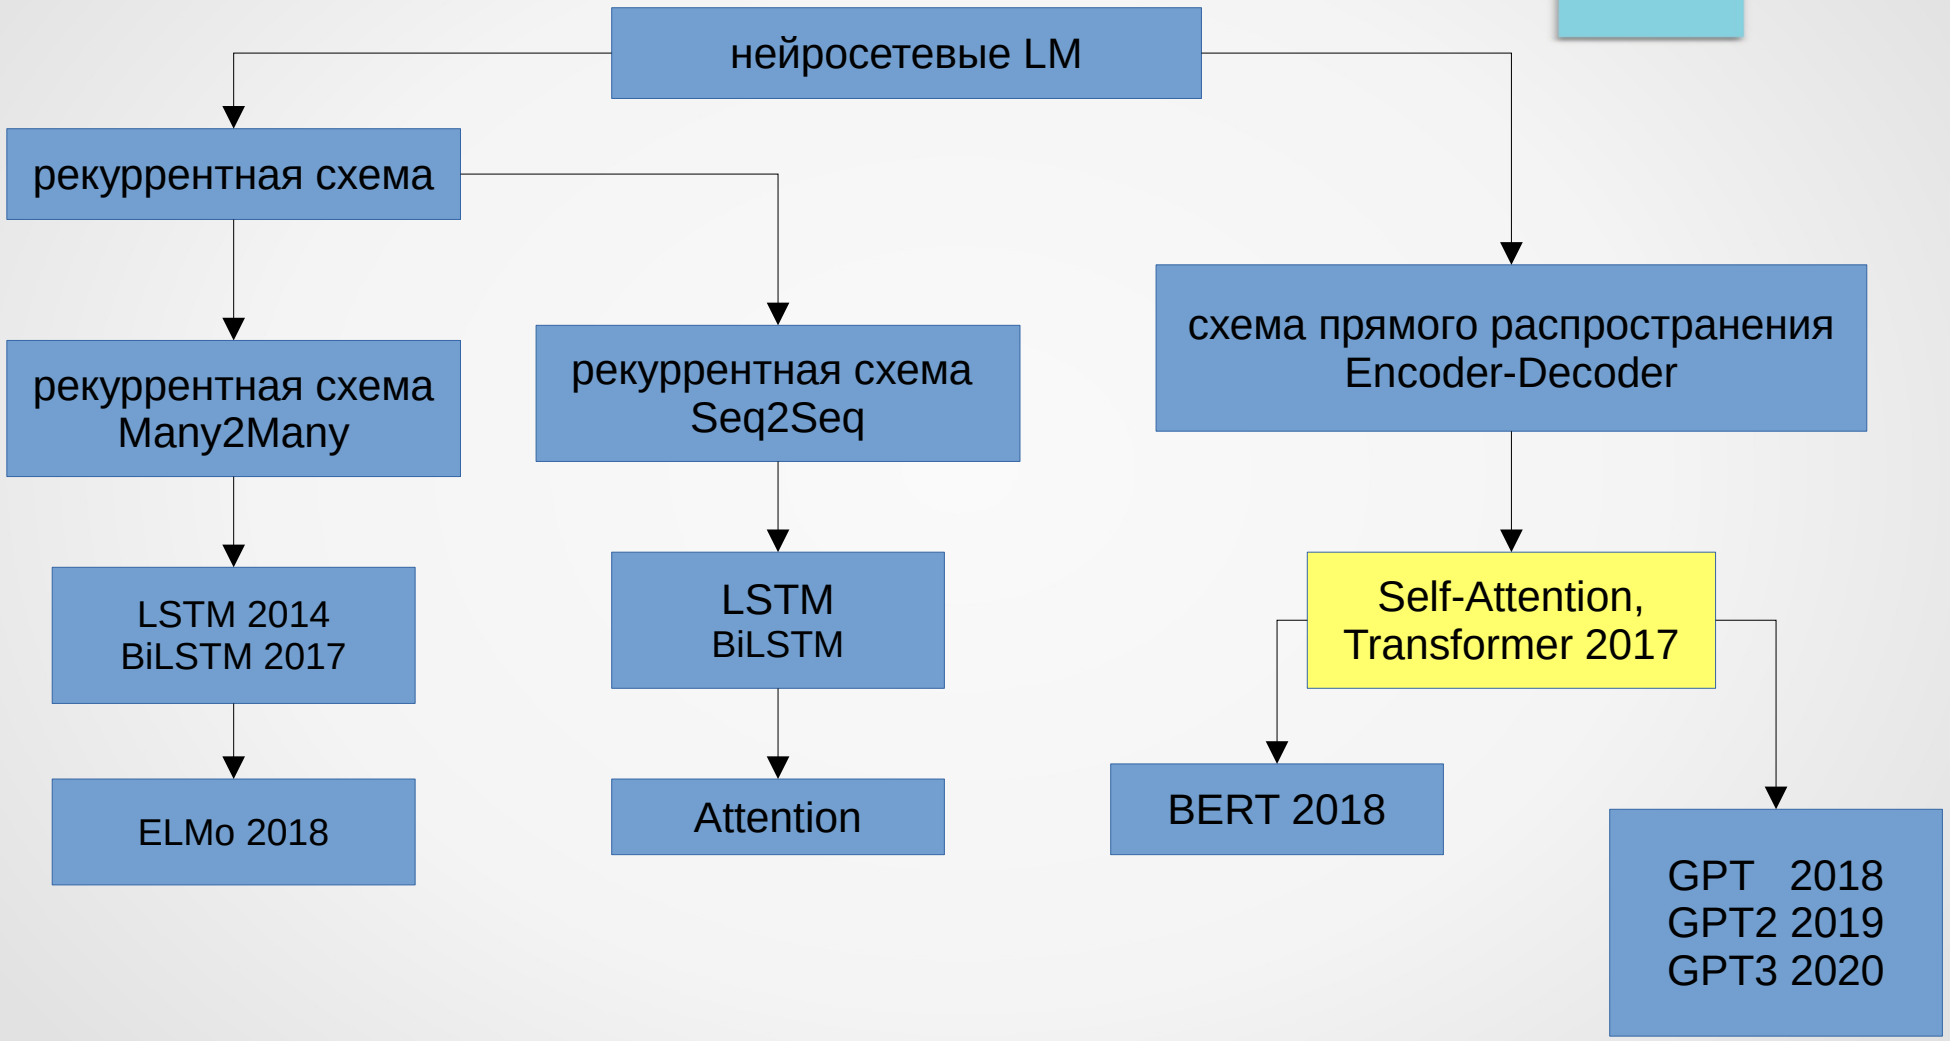

# Нейросетевые языковые модели

## Схема Encoder-Decoder прямого распространения

**Модель Transformer и механизм Self-Attention**
Attention Is All You Need (2017) https://arxiv.org/abs/1706.03762

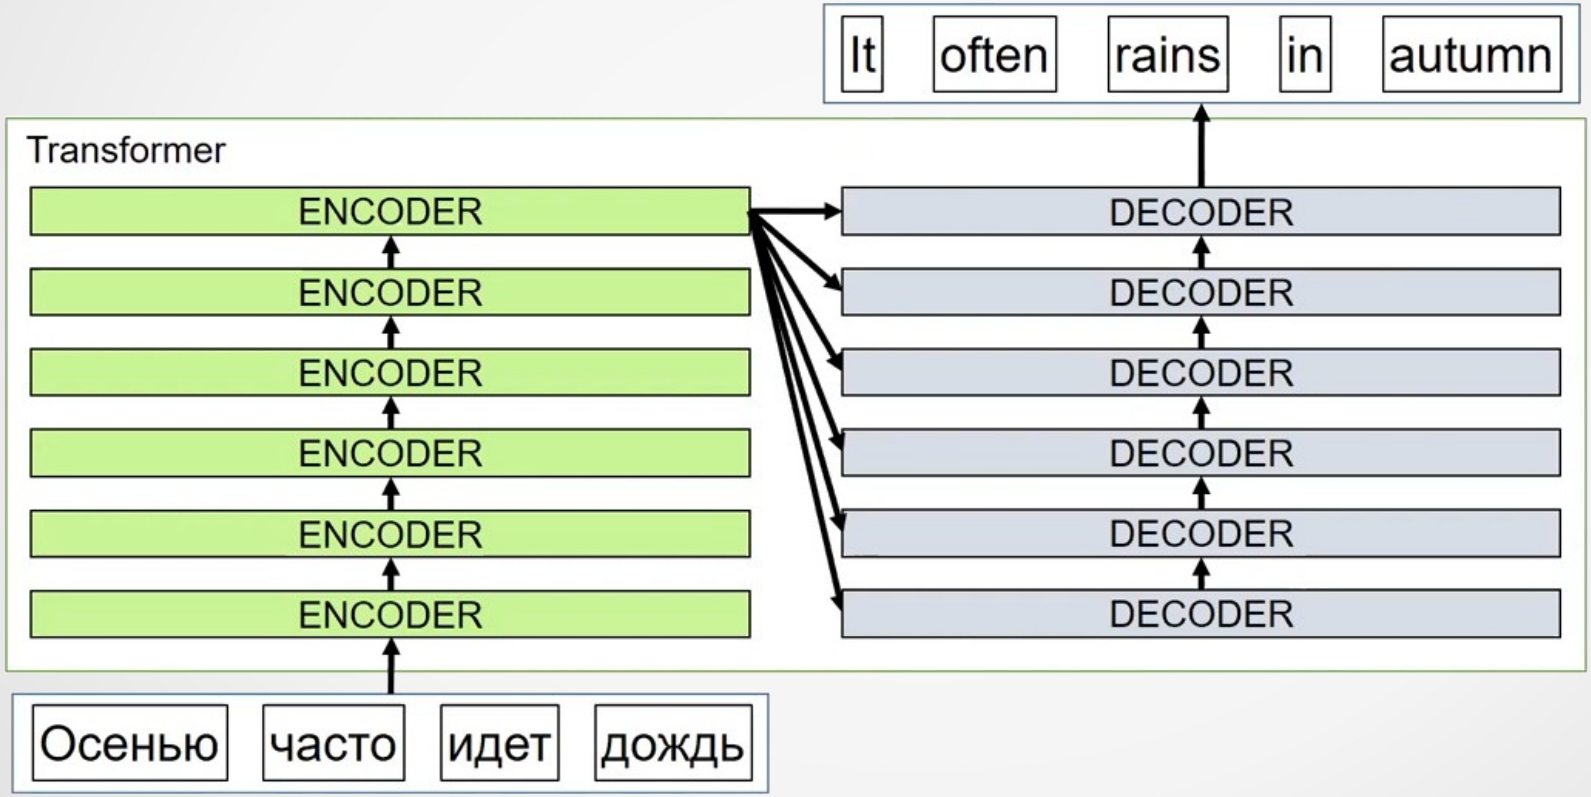


**токенизация BPE (Byte Pair Encoding)**
Sennrich R., et al. Neural machine translation of rare words with subword units– 2015.

https://www.youtube.com/watch?v=_8MGdpt4I9M

# Нейросетевые языковые модели

**Transformer: Энкодер**

- блок внимания MHSA

- skip connection, normalization

- сеть прямого распространения

все слова подаём в модель одновременно,
они обрабатываются совместно,

схема вычислений хорошо распараллеливается

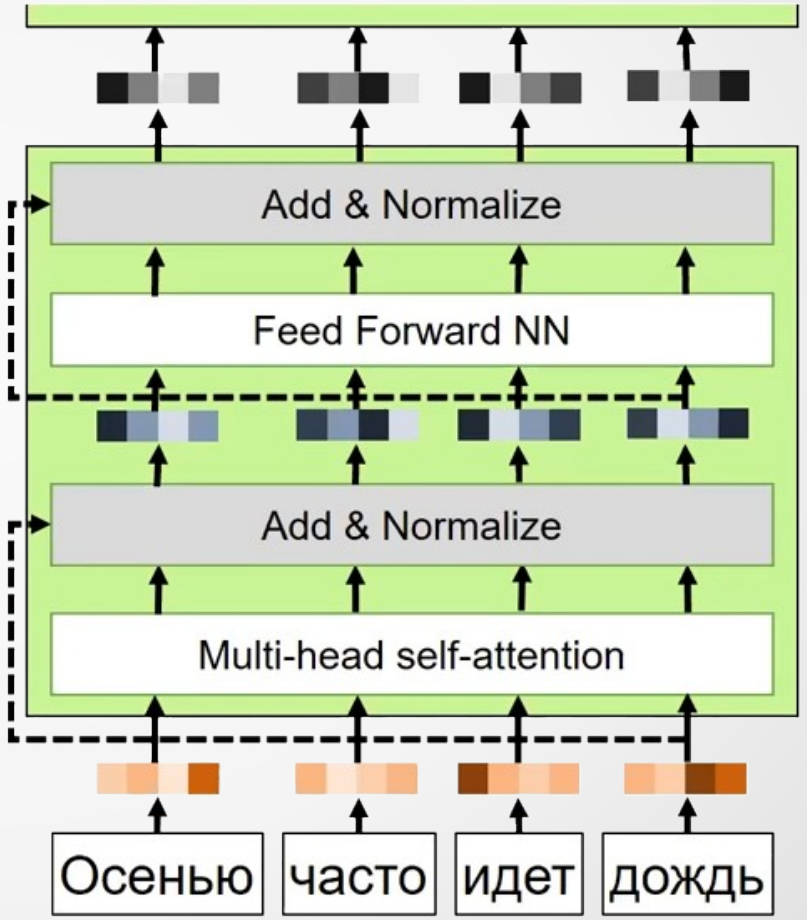


https://www.youtube.com/watch?v=_8MGdpt4I9M

# Нейросетевые языковые модели

**`Transformer: Encoder : Self-Attention`**

**query** - откуда смотрим (из какого слова)
**key** - куда смотрим (на какое слово)
**value** - смысл (условно) слова

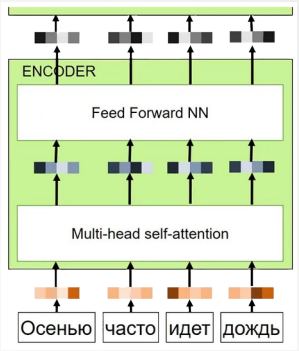


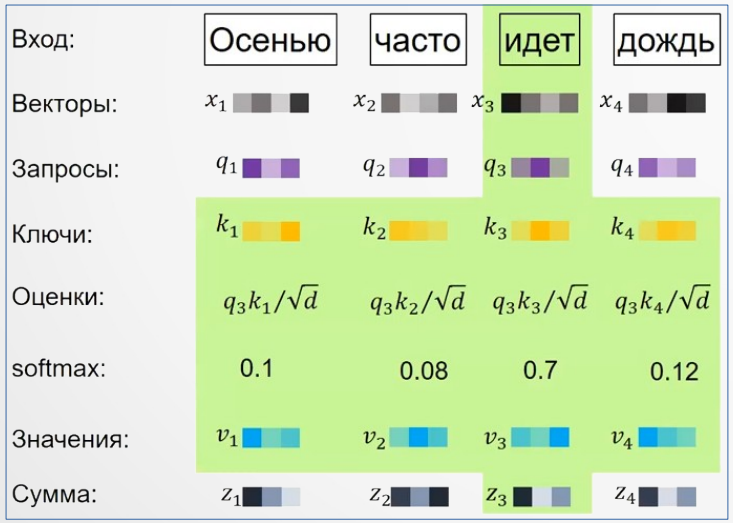


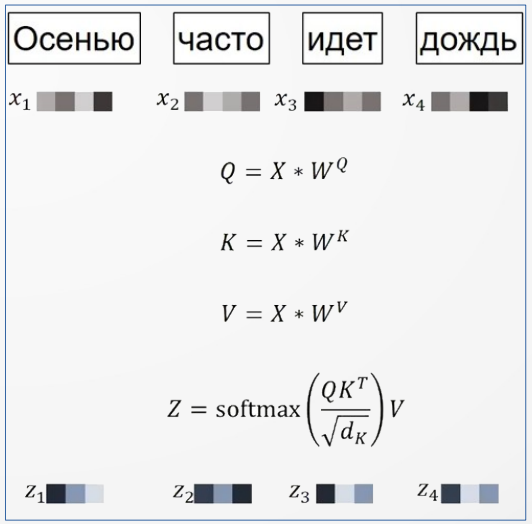


все слова подаём в модель одновременно,
они обрабатываются совместно,
схема вычислений хорошо распараллеливается

https://www.youtube.com/watch?v=_8MGdpt4I9M

# Нейросетевые языковые модели

**Transformer: Encoder : Multi-Head-Self-Attention**

Используем параллельно несколько блоков Self-Attention с разными весами

Результаты агрегируются в размер входа X для стекирования блоков энкодера

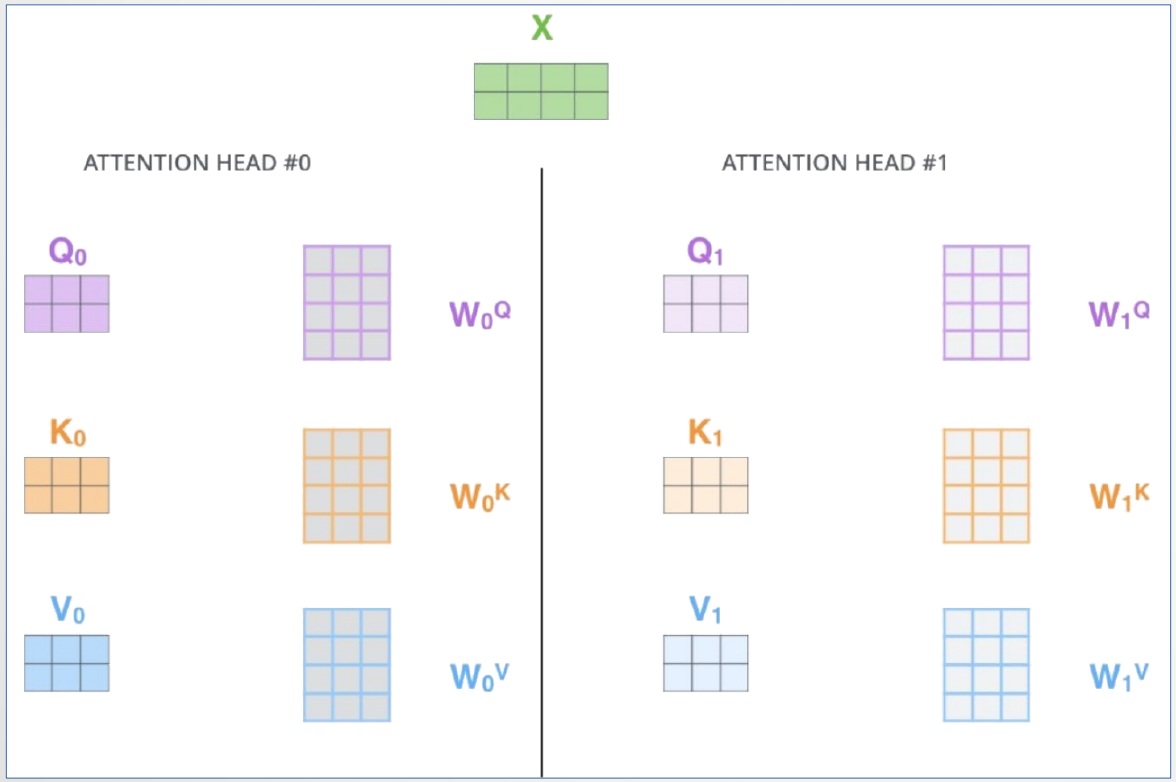


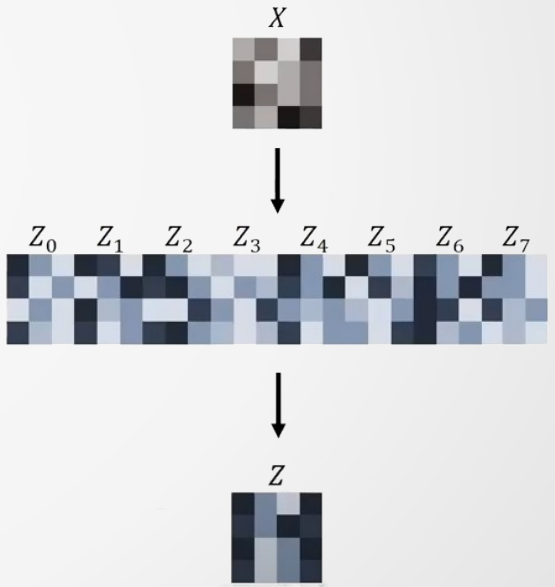

# Нейросетевые языковые модели

**Transformer: Encoder : Multi-Head-Self-Attention**

1) This is our input sentence*

2) We embed each word*

3) Split into 8 heads. We multiply X with weight matrices

4) Calculate attention using the resulting Q/K/V matrices

5) Concatenate the resulting Z matrices, then multiply with weight matrix $W^O$ to produce the output of the layer

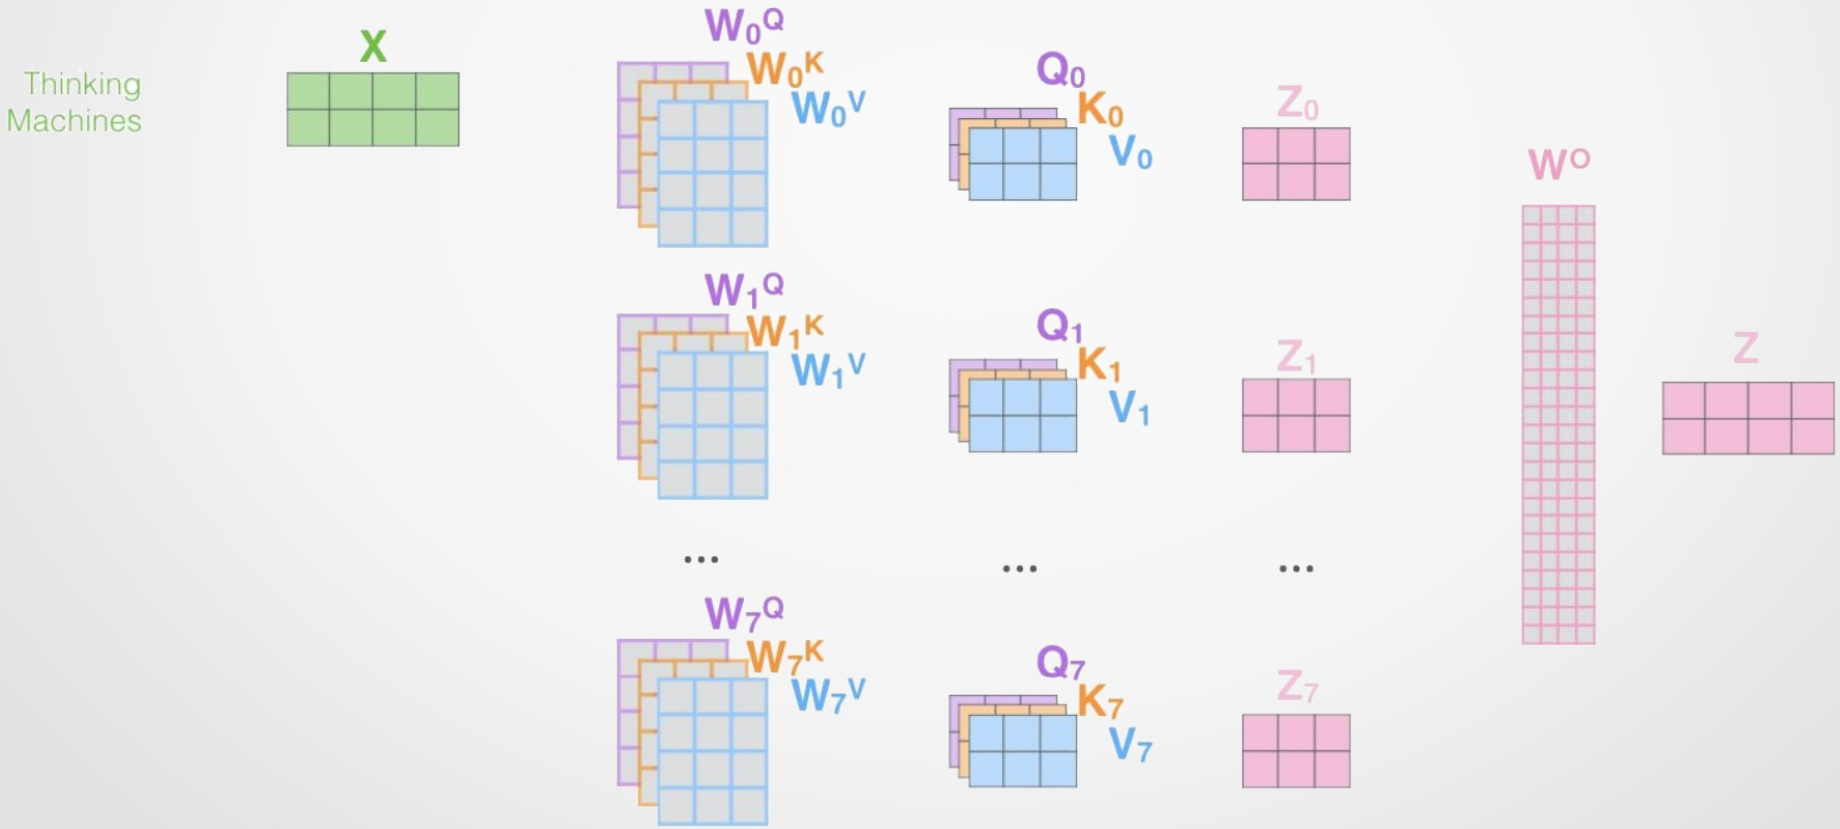


Image source: https://jalammar.github.io/illustrated-transformer/

# Нейросетевые языковые модели

**Transformer: Encoder**

Проблема: не учитывается порядок слов

Решение: positional encoding

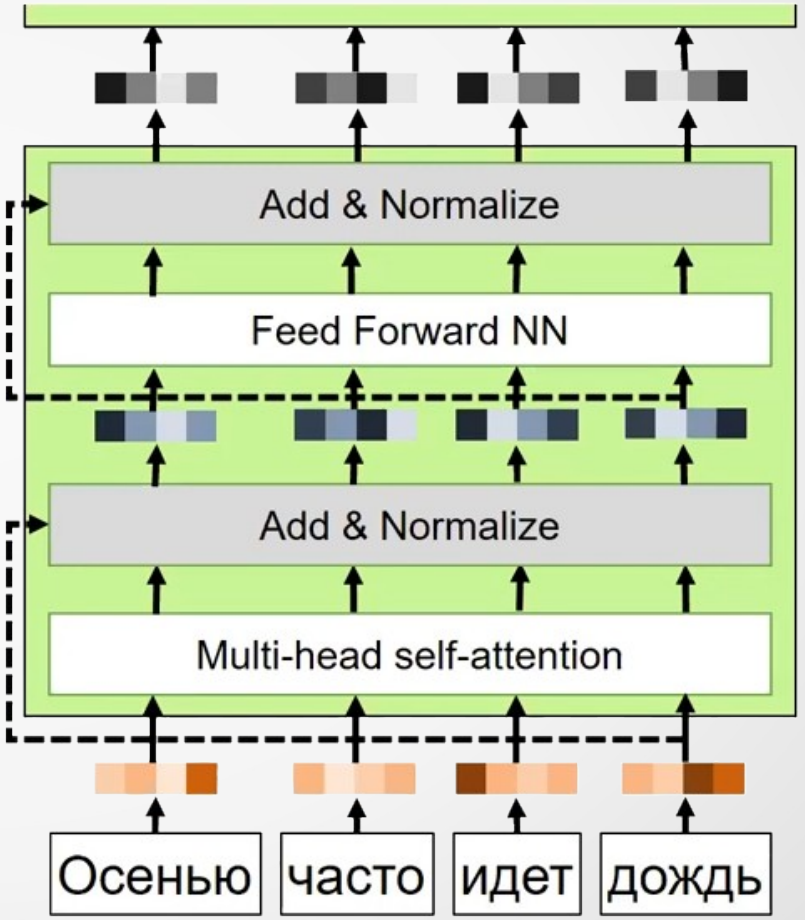


https://www.youtube.com/watch?v=_8MGdpt4I9M

# Нейросетевые языковые модели

**Transformer: Encoder : Positional encoding**

Необходимо обозначить позицию слова, выполняя условия
- уникальность для каждого слова
- не зависит от длинны предложения
- детерминирован (не стохастический)

$$\vec{p_t}^{(i)} = f(t)^{(i)} = \begin{cases} \sin(\omega_k t), & \text{if } i = 2k \\ \cos(\omega_k t), & \text{if } i = 2k+1 \end{cases}$$

$$\omega_k = \frac{1}{10000^{2k/d}}$$

$$\vec{p_t} = \begin{bmatrix} \sin(\omega_1.t) \\ \cos(\omega_1.t) \\ \sin(\omega_2.t) \\ \cos(\omega_2.t) \\ \vdots \\ \sin(\omega_{d/2}.t) \\ \cos(\omega_{d/2}.t) \end{bmatrix}_{d \times 1}$$

t - номер слова в строке
d - размерность входа модели
k - номер элемента в векторе PE

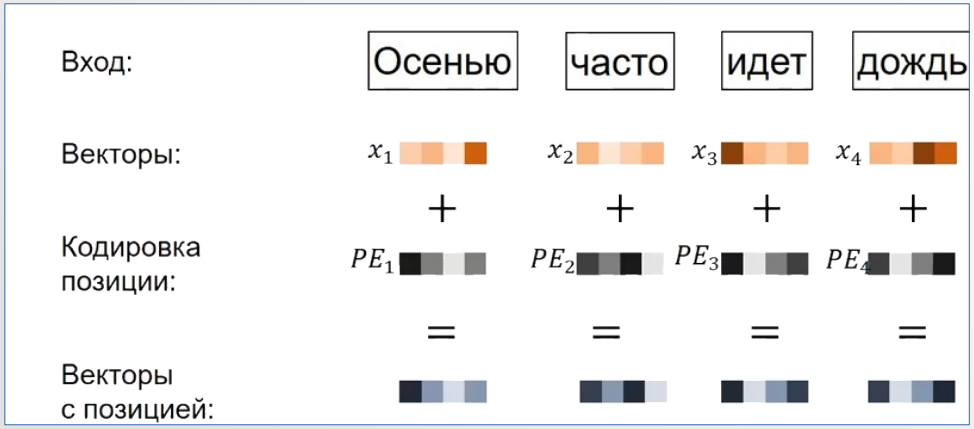


PE - не обучается вместе с моделью, но вычисляется по формуле

длина последовательности ограничена

# Нейросетевые языковые модели

**Transformer: Decoder**

авторегрессионная модель - выход подаём на вход

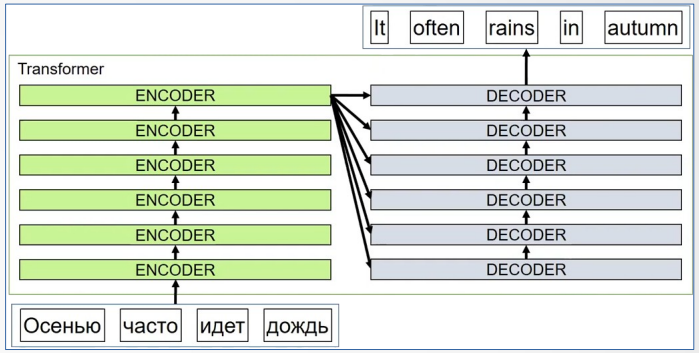


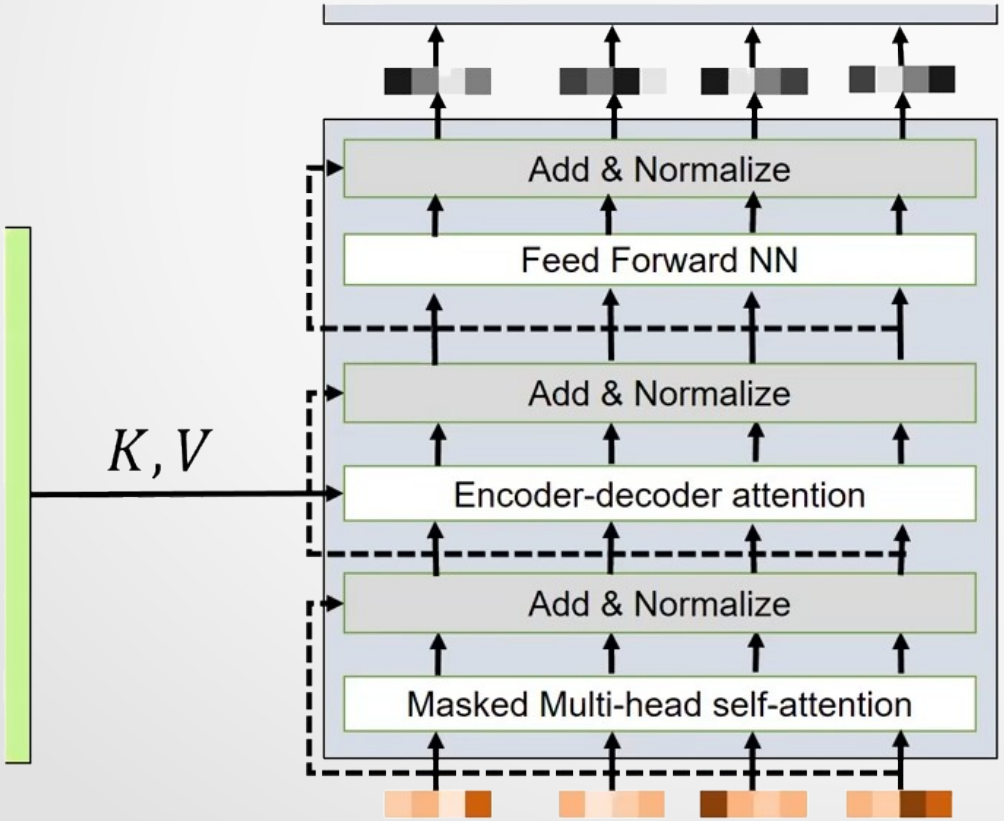


- encoder-decoder attention, используем [K,V] из последнего блока encoder

- masked MHSA
при расчёте self-attention используем только левый контекст

# Нейросетевые языковые модели

**Transformer: Decoder : Musked Multi-Head-Self-Attention**

в процессе обучения модели,
при расчёте self-attention используем только левый контекст

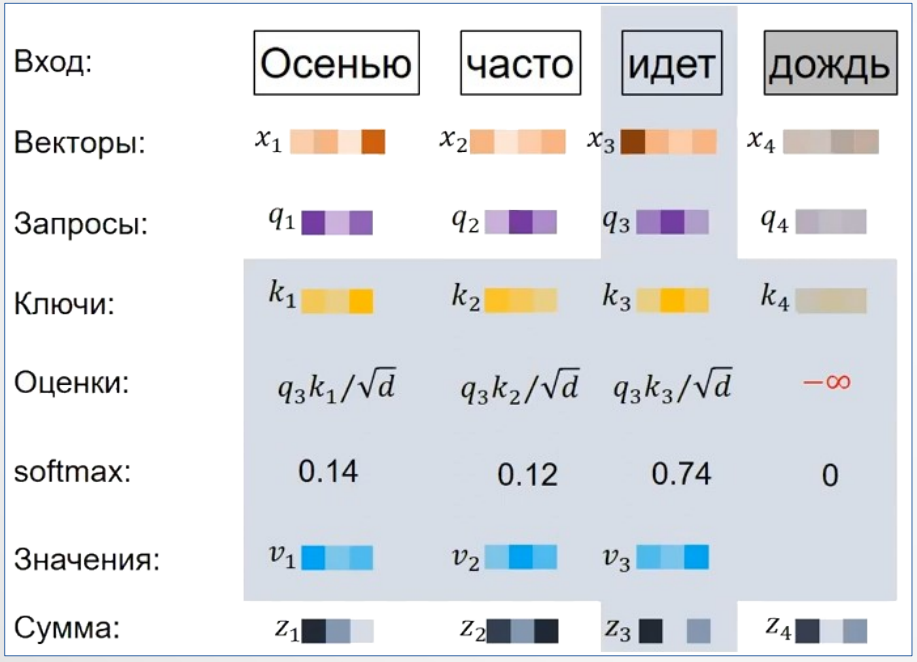


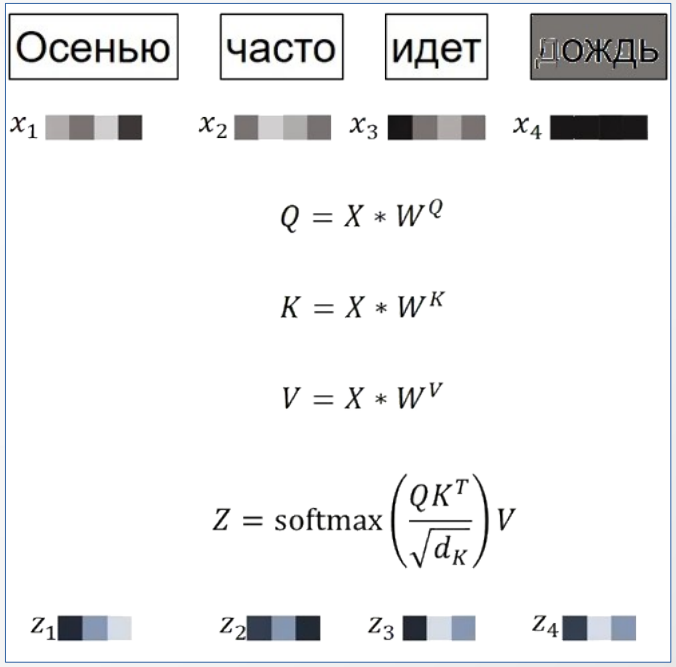

# Нейросетевые языковые модели

**Transformer: Decoder : Encoder-Decoder Attention**

используем [K,V] берём из последнего блока encoder

похоже на Attention из рекуррентных SEQ2SEQ

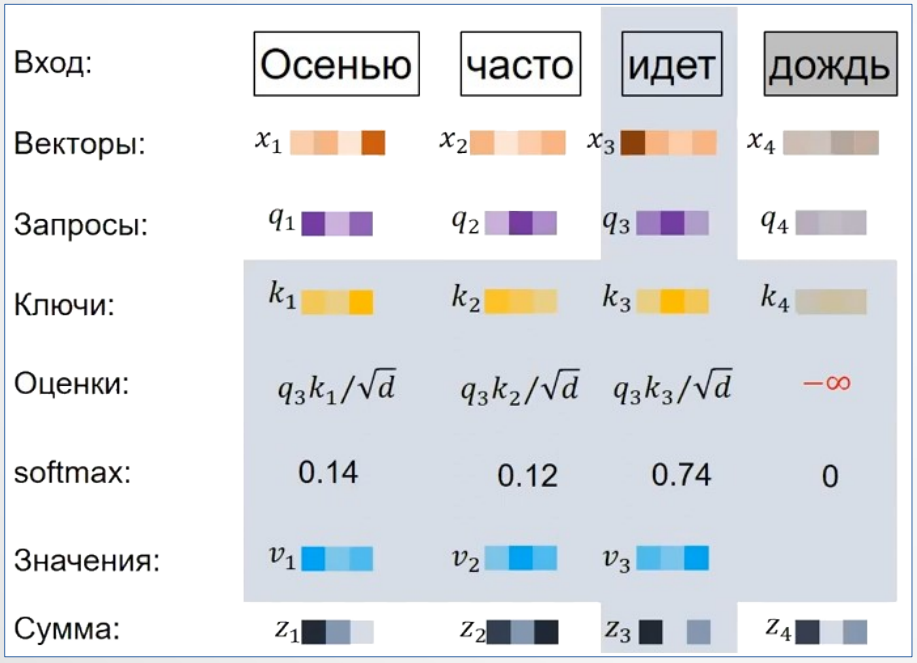


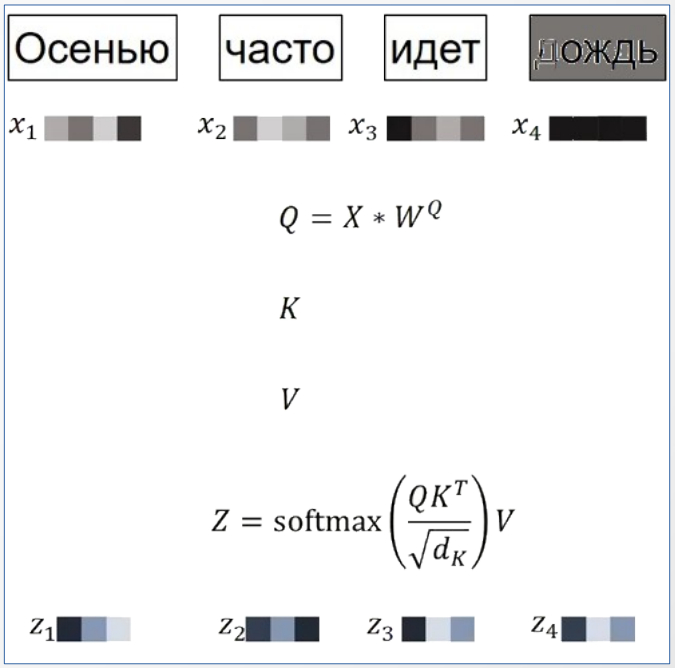

# Нейросетевые языковые модели

## Схема Encoder-Decoder прямого распространения

### Модель Transformer и механизм Self-Attention

Attention Is All You Need (2017) https://arxiv.org/abs/1706.03762

**токенизация BPE (Byte Pair Encoding)**
Sennrich R., et al. Neural machine translation of rare words with subword units– 2015.

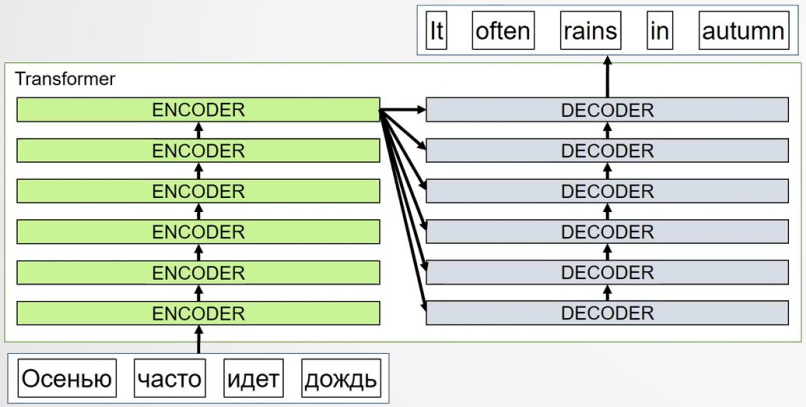


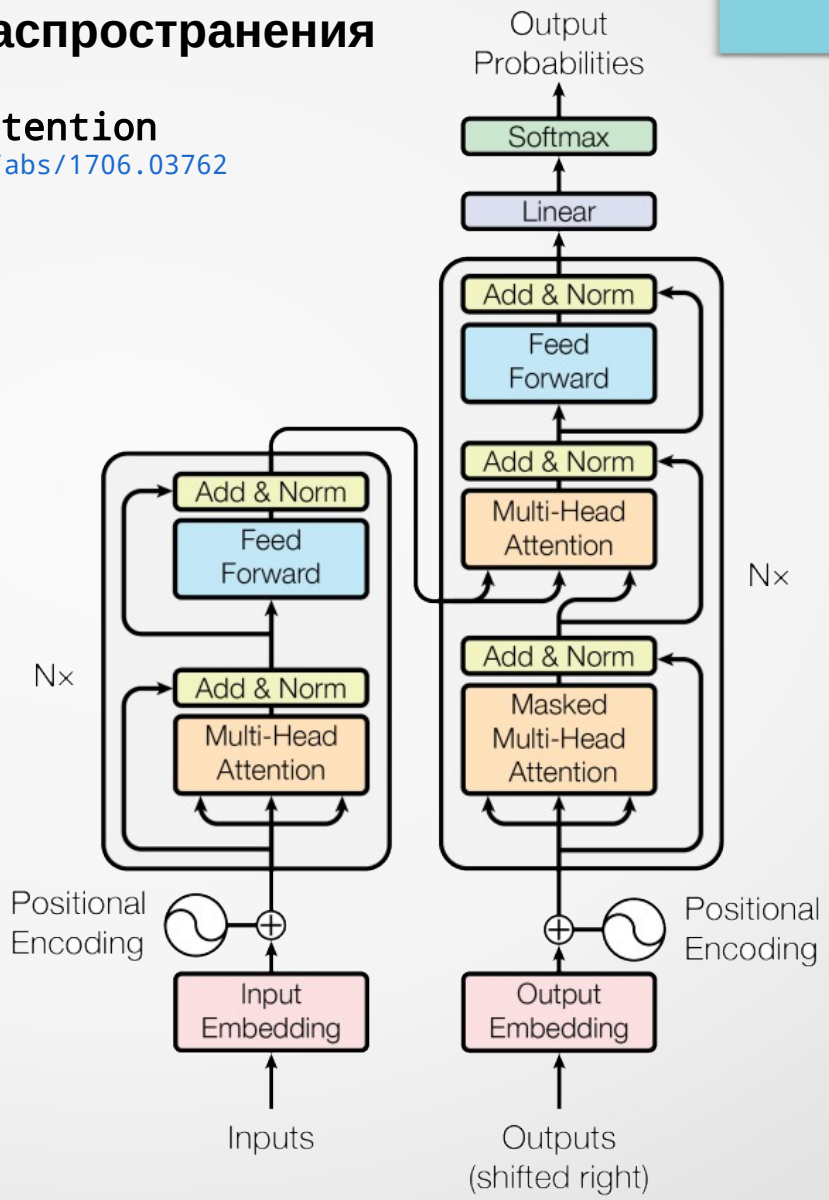


https://www.youtube.com/watch?v=_8MGdpt4I9M

# Нейросетевые языковые модели

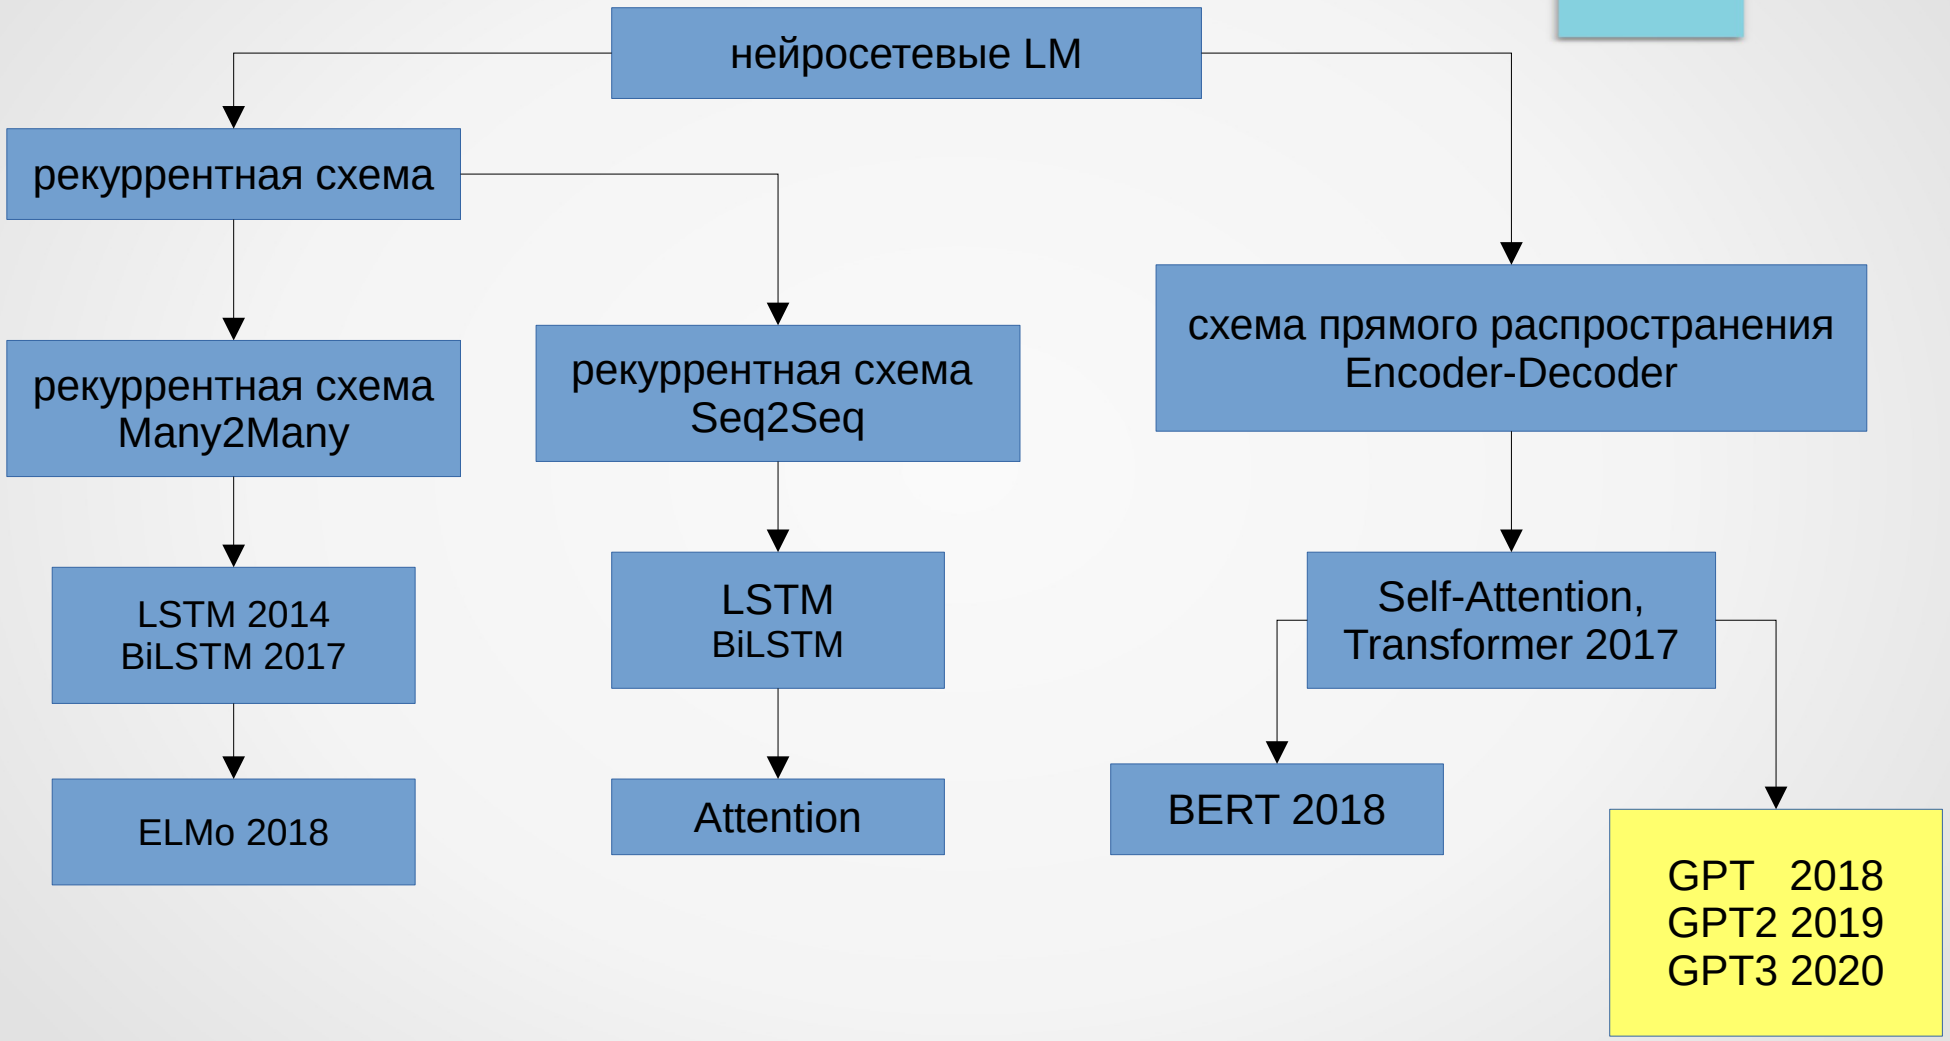

# Нейросетевые языковые модели

**Модели GPT (Generative Pre-Training)**
Radford A. et al. Improving language understanding by generative pre-training. – 2018

Языковая модель, основанная на блоке Decoder модели Transformer, блок Encoder-Decoder-Attention выкидываем.

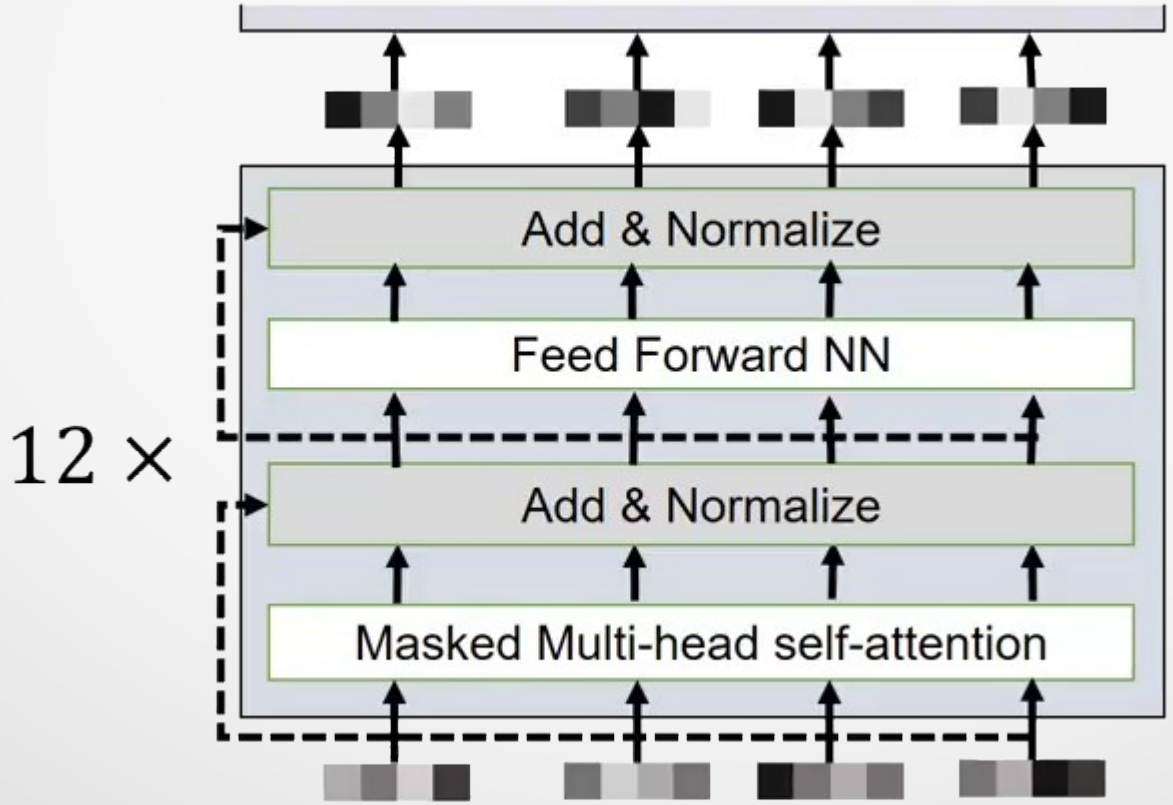

# Нейросетевые языковые модели

**Модели GPT (Generative Pre-Training)**

Radford A. et al. Improving language understanding by generative pre-training. – 2018

Схема обучения модели на основе GPT

- Предобучение на корпусе $\mathcal{U}$ (без учителя)

$$h_0 = UW_e + W_p;$$
$$h_i = \text{transformer}(h_{i-1}), i = \overline{1,n}$$
$$P(u) = \text{softmax}(h_n W_e^T)$$

$$L_1(\mathcal{U}) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta)$$

- Донастройка под целевую задачу на корпусе $\mathcal{C}$ (с учителем)

$$P(y|x^1, \dots, x^m) = \text{softmax}\left(h_l^m W_y\right)$$
$$L_2(\mathcal{C}) = \sum_{(x,y)} \log P(y|x^1, \dots, x^m)$$

$$L(\mathcal{C}) = L_2(\mathcal{C}) + \lambda * L_1(\mathcal{C});$$

# Нейросетевые языковые модели

**Модели GPT (Generative Pre-Training)**

Radford A. et al. Improving language understanding by generative pre-training. – 2018

Различные варианты применения GPT

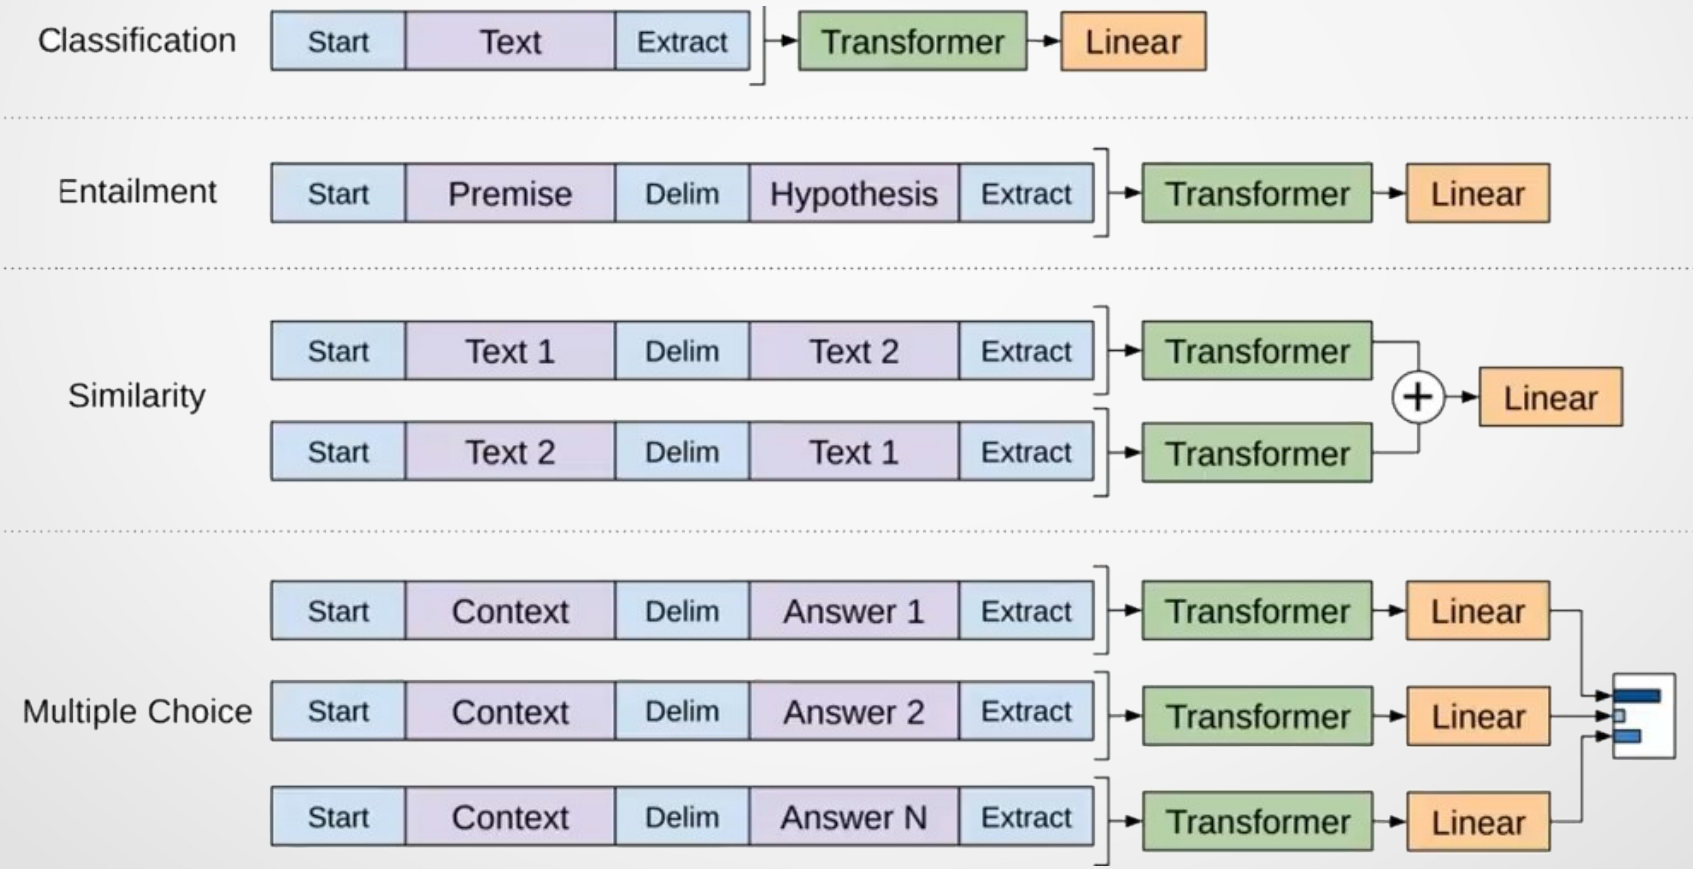

# Нейросетевые языковые модели

**Модели GPT (Generative Pre-Training)**

GPT: Radford A. et al. Improving language understanding by generative pre-training. – 2018
- 12 слоев трансформера

GPT-2: Radford A. et al. Language models are unsupervised multitask learners – 2019
- 48 слоев трансформера
- Больше корпус для обучения (40 GB текста)
- Другая токенизация: BPE по байтам, а не по символам
- передвинут Layer normalization
- изменена инициализация

GPT-3: Brown T. B. et al. Language models are few-shot learners – 2020.
(почти не отличается от GPT-2)
- 96 слоев трансформера
- Еще больше корпус для обучения (570 GB текста)
- Еще больше контекст (2048 токенов)

# Нейросетевые языковые модели

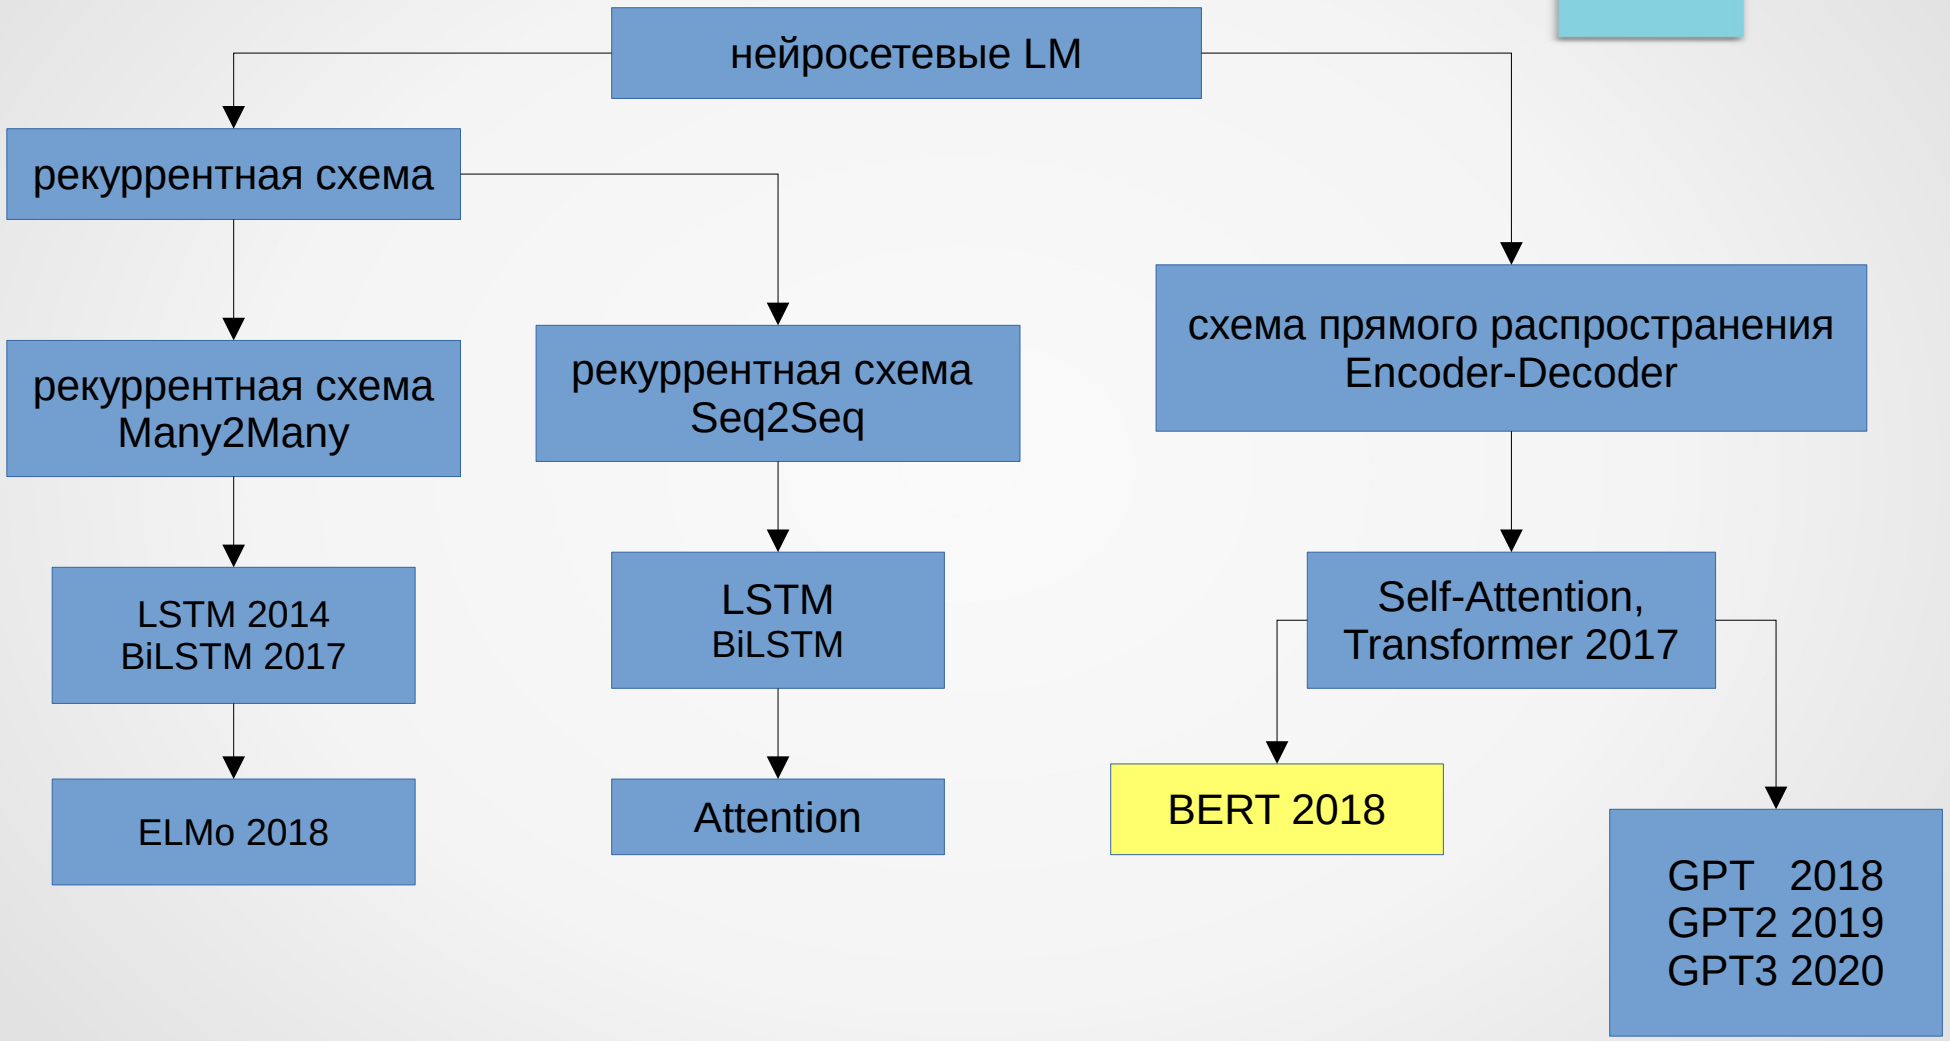

# Нейросетевые языковые модели

**BERT (Bidirectional Encoder Representation Transformers)**

Devlin J. et al. Bert: Pre-training of deep bidirectional transformers for language understanding – 2018.

Языковая модель, основанная на Transformer Encoder

BERT Base – 12 блоков

BERT Large - 24 блока

$12(24) \times$

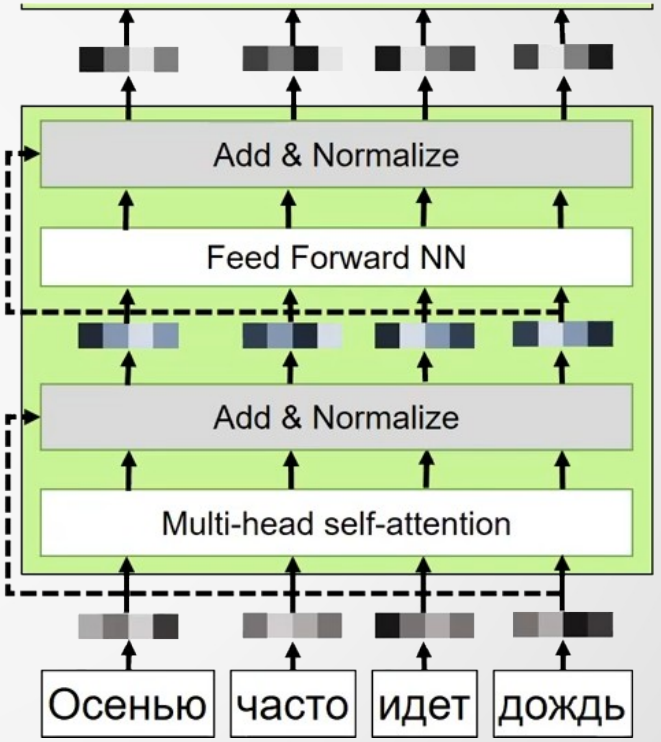


применяем обучаемый Positional Encoding

данные для обучение разбиты на пары предложений

обучаем модель определять связаны ли два предложения

маскируем слова и обучаем модель их предсказывать

# Нейросетевые языковые модели

## BERT (Bidirectional Encoder Representation Transformers)

Devlin J. et al. Bert: Pre-training of deep bidirectional transformers for language understanding – 2018.

- обучаемый Positional Encoding + дополнительный вектор номера сегмента

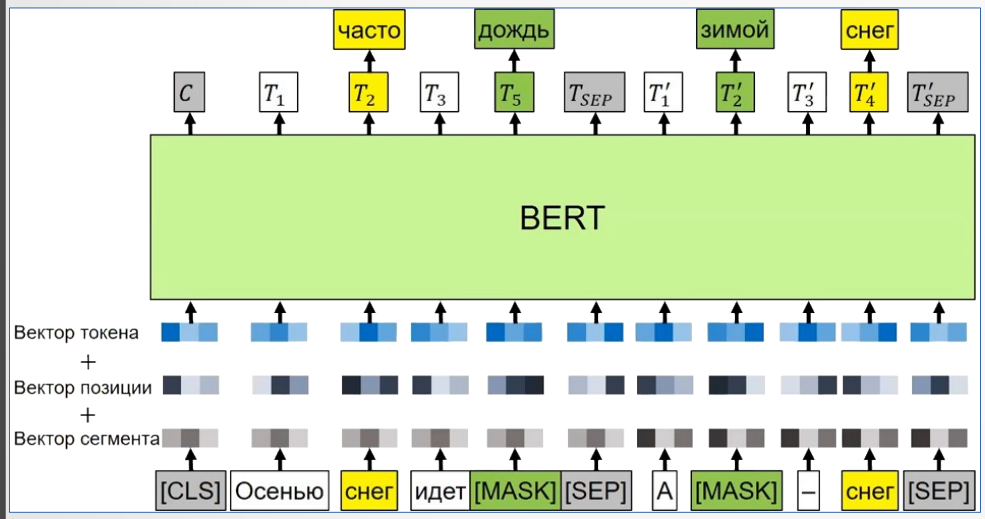


- маскируем слова и обучаем модель их предсказывать
15% токенов могут маскироватся, из них:
- 80% - [MASK];
- 10% - подменяем на случайные;
- 10% - оставляем;

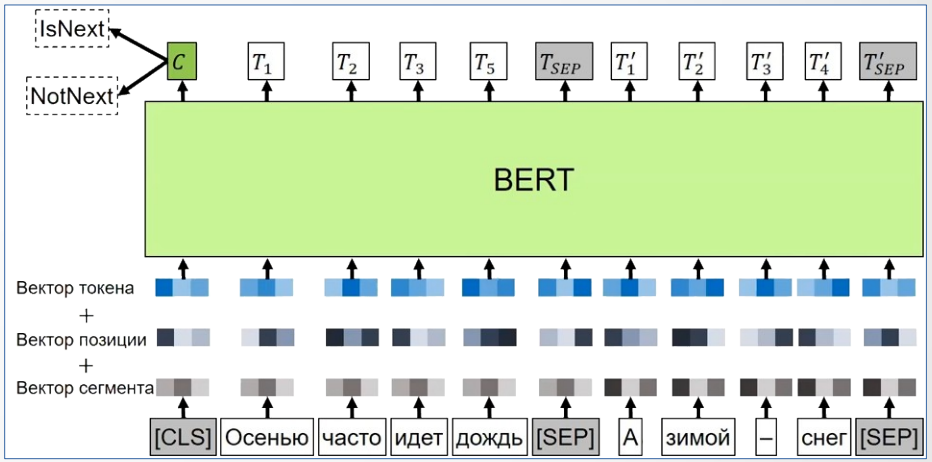


- обучаем модель определять связаны ли сегменты (опционально)

# Нейросетевые языковые модели

git clone *https://github.com/mechanoid5/ml_nlp.git*

Майоров В.Д.
Основы обработки текстов. Лекция 10. Языковвые модели. ИСП РАН, 2021
https://www.youtube.com/watch?v=_8MGdpt4I9M

Нейчев Радослав
Прикладное машинное обучение 3. Machine translation. Лекторий ФПМИ, 2020
https://www.youtube.com/watch?v=6HibilFua-U